

Análisis Exploratorio de Datos

Alberto Barradas

0.1 Temario

- Muestreo y Distribución Probabilística
- Estadísticas Descriptivas
- Histogramas y Densidades
- Distribución Normal
- Distribución t de Student
- Esquema de Tests de Hipótesis
- Pruebas Paramétricas y No Paramétricas

0.2 Recordatorio

En Probabilidad y Estadística, una variable aleatoria es **una función que asigna un valor numérico al resultado de un experimento aleatorio**.

La variable no tiene un solo valor numérico, sino que puede tomar varios valores numéricos, cada uno con una cierta probabilidad.

Una forma de describir esa probabilidad es mediante una función de probabilidad, que asigna a cada valor numérico posible de la variable aleatoria una probabilidad.

```
using GLMakie
using Distributions, Random, HypothesisTests

U = 1000
N = 10
X = rand(U)
t = sample(1:length(X), N)
x = X[t]
fig = Figure(size=(800, 600));
ax = Axis(fig[1, 1], subtitle="Muestra de Población")
```

```
scatter!(ax, X, color=:teal)
scatter!(ax, t, x, color=:coral, marker=:xcross, markersize=20)
fig
```

[Info: Precompiling GeometryBasicsExt [b238bd29-021f-5edc-8b0e-16b9cda5f63a] (cache misses: 0)
 [Info: Precompiling UnitfulExt [0e51ec96-f580-5f12-a625-1297083d7970] (cache misses: wrong d
 [Info: Precompiling FileIOExt [f5f51d8f-5827-5d2e-939b-192fcd6ec70c] (cache misses: wrong d




Figure 1: Muestreo de una población

0.3 Muestreo

```
# Muestreo de una población
U = 10000
```

```

N = 10
X = Observable(rand(U))
t = Observable(sample(1:length(X[]), N))
x = Observable(X[][t[]])
fig = Figure(size=(1600, 600));
ax = Axis(fig[1, 1], subtitle="Muestra de Población")
scatter!(ax, X, color=:teal)
scatter!(ax, t, x, color=:coral, marker=:xcross, markersize=20)
ax = Axis(fig[1, 2], subtitle="Distribución")
density!(ax, X, color=:teal)
hist!(ax, x, color=:coral, normalization=:pdf, bins=100)
button = Button(fig[2, :], label="Tomar Nueva Muestra")
l = on(button.clicks) do b
    t[] = sample(1:length(X[]), N)
    x[] = X[][t[]]
end
# sg = SliderGrid(fig[2,1],
#     (label="N", range=1:1:N, startvalue=N),
# )
# sliderobservables = [s.value for s in sg.sliders]
# bars = lift(sliderobservables...) do N
#     t[] = sample(1:length(X[]), N)
#     x[] = X[][t[]]
# end
fig

```




Figure 2: Muestreo de una población

0.4 Distribución de Probabilidad

Hemos utilizado distribuciones uniformes, como las de aventar un dado. Estas variables aleatorias pueden tomar cualquiera de sus valores con la misma probabilidad, pero esto no tiene que ser así. Si un dado está cargado, la probabilidad de que salgan ciertos números es mayor que otros.

Una distribución de probabilidad describe cómo se distribuyen los valores de una variable aleatoria y la probabilidad de que la variable aleatoria tome un valor específico.

Recomendamos que memoricen dos distribuciones de probabilidad con sus parámetros:

```
U = 1000
N = 30
X = Observable(rand(Normal(0, 1), U))
# X = Observable(rand(Uniform(0, 1), U))
# X = Observable(rand(Exponential(1), U))
# X = Observable(rand(Binomial(10, 0.5), U))
t = Observable(sample(1:length(X[]), N))
x = Observable(X[] [t[]])
fig = Figure(size=(1600, 600));
ax = Axis(fig[1, 1], subtitle="Muestra de Población")
scatter!(ax, X, color=:teal)
scatter!(ax, t, x, color=:coral, marker=:xcross, markersize=20)
ax = Axis(fig[1, 2], subtitle="Distribución")
density!(ax, X, color=:teal)
hist!(ax, x, color=:coral, normalization=:pdf)
button = Button(fig[2, 1:2], label="Tomar Nueva Muestra")
l = on(button.clicks) do b
    x[] = sample(X[], N)
    println("Estadísticas Descriptivas de la Muestra:")
    println("Media: ", mean(x[]))
    println("Mediana: ", median(x[]))
    println("Desviación Estándar: ", std(x[]))
end
fig
```




Figure 3: Distribuciones de Probabilidad

0.5 Distribución normal

No todas las distribuciones aleatorias tienen la misma probabilidad de ocurrencia. La distribución normal es una de las distribuciones más comunes en estadística: es simétrica y tiene una forma de campana. También es una distribución continua, lo que significa que puede tomar cualquier valor en un rango continuo.

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

```
U = 10000
N = 10
X = Observable(rand(Normal(0, 1), U))
t = Observable(sample(1:length(X[]), N))
x = Observable(X[] [t[]])
fig = Figure(size=(1600, 600));
ax = Axis(fig[1, 1], subtitle="Muestra de Población")
scatter!(ax, X, color=:mediumaquamarine)
scatter!(ax, t, x, color=:lightcoral, marker=:xcross, markersize=20)
ax = Axis(fig[1, 2], subtitle="Distribución")
density!(ax, X, color=:mediumaquamarine)
hist!(ax, x, color=:lightcoral, normalization=:pdf)
button = Button(fig[2, 1:2], label="Tomar Nueva Muestra")
l = on(button.clicks) do b
    x[] = sample(X[], N)
end
fig
```




Figure 4: Distribucion Normal

La distribución normal puede ser descrita por dos parametros: μ y σ , que representan la media y la desviación estándar de la distribución. Cambiando los valores de μ y σ , podemos cambiar la forma de la distribución:

```
U = 10000
N = 10
= Observable(0.0)
= Observable(1.0)
X = Observable(rand(Normal( [], []), U))
t = Observable(sample(1:length(X[]), N))
x = Observable(X[][t[]])
fig = Figure(size=(1600, 600));
ax = Axis(fig[1, 1], subtitle="Muestra de Población")
scatter!(ax, X, color=:mediumaquamarine)
scatter!(ax, t, x, color=:lightcoral, marker=:xcross, markersize=20)
ax = Axis(fig[1, 2], subtitle="Distribución")
density!(ax, X, color=:mediumaquamarine)
hist!(ax, x, color=:lightcoral, normalization=:pdf)
sg = SliderGrid(fig[2,1],
    (label=" ", range=-10:0.1:10, format="{:.2f}", startvalue=0.0),
    (label=" ", range=0.1:0.1:5, format="{:.2f}", startvalue=1.0),
)
sliderobservables = [s.value for s in sg.sliders]
bars = lift(sliderobservables...) do ,
    X[] = rand(Normal( , ), U)
```

```

t[] = sample(1:length(X[]), N)
x[] = X[][t[]]
println("Estadísticas Descriptivas de la Muestra:")
println("Media: ", mean(x[]))
println("Mediana: ", median(x[]))
println("Desviación Estándar: ", std(x[]))
end
fig

```

Estadísticas Descriptivas de la Muestra:
Media: 0.3776078323013577
Mediana: 0.34968132378723515
Desviación Estándar: 1.0035205662402964




Figure 5: Parámetros de la Distribución Normal

Generando una distribución sintética para tres valores de :

```

[ Info: Precompiling CSV [336ed68f-0bac-5ca0-87d4-7b16caf5d00b] (cache misses: wrong dep ver:
[ Info: Precompiling DataFramesExt [9e668153-f473-5010-85ff-a85cbe3b95ea] (cache misses: wron

```

"normal_samples_small_effect.csv"

Parámetros de la Distribución Normal




Figure 6: Parámetros de la Distribución Normal

```
Random.seed!(42) # para reproducibilidad
N = 30
1 = 0.0
1 = 1.0
2 = 0.5
2 = 1.0
X1 = rand(Normal(1, 1), N)
X2 = rand(Normal(2, 2), N)
df = DataFrame(mu=Float64[], sigma=Float64[], sample=Float64[])
for val in X1
    push!(df, (1, 1, val))
end
for val in X2
    push!(df, (2, 2, val))
end
CSV.write("normal_samples_medium_effect.csv", df)
```

"normal_samples_medium_effect.csv"

Parámetros de la Distribución Normal

0.6 Distribución t de Student

La distribución t de Student es una distribución de probabilidad continua que se utiliza para estimar la media de una población cuando el tamaño de la muestra es pequeño y/o la desviación

estándar de la población es desconocida. La distribución t de Student es similar a la distribución normal, pero tiene colas más gruesas, lo que significa que hay una mayor probabilidad de obtener valores extremos.

$$f(t|\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

```
U = 1000
N = 30
df = Observable(29) # grados de libertad
X = Observable(rand(TDist(df[]), U))
t = Observable(sample(1:length(X[]), N))
x = Observable(X[][t[]])
fig = Figure(size=(1600, 600));
ax = Axis(fig[1, 1], subtitle="Muestra de Población")
scatter!(ax, X, color=:mediumaquamarine)
scatter!(ax, t, x, color=:lightcoral, marker=:xcross, markersize=20)
ax = Axis(fig[1, 2], subtitle="Distribución")
density!(ax, X, color=:mediumaquamarine)
hist!(ax, x, color=:lightcoral, normalization=:pdf)
button = Button(fig[2, 1:2], label="Tomar Nueva Muestra")
l = on(button.clicks) do b
    x[] = sample(X[], N)
    println("Estadísticas Descriptivas de la Muestra:")
    println("Media: ", mean(x[]))
    println("Mediana: ", median(x[]))
    println("Desviación Estándar: ", std(x[]))
end
fig
```




Figure 7: Distribución t de Student

Comparada con la distribución normal, la distribución t de Student tiene colas más gruesas, lo que significa que hay una mayor probabilidad de obtener valores extremos. A medida que el tamaño de la muestra aumenta, la distribución t de Student se aproxima a la distribución normal.

```
U = 10000
N = Observable(5)
df = N[] - 1 # grados de libertad
X1 = Observable(rand(Normal(0, 1), U))
X2 = Observable(rand(TDist(df), U))
t = Observable(sample(1:length(X1[]), N[]))
x1 = Observable(X1[] [t[]])
x2 = Observable(X2[] [t[]])
fig = Figure(size=(1600, 600));
ax = Axis(fig[1, 1], subtitle="Muestra de Población")
scatter!(ax, X1, color=:teal, label="Normal")
scatter!(ax, t, x1, color=:coral, marker=:xcross, markersize=20)
scatter!(ax, X2, color=:mediumaquamarine, label="t Student")
scatter!(ax, t, x2, color=:lightcoral, marker=:xcross, markersize=20)
axislegend(ax)
ax = Axis(fig[1, 2], subtitle="Distribución")
density!(ax, X1, color=:teal, label="Normal")
hist!(ax, x1, color=:coral, normalization=:pdf, label="Normal")
density!(ax, X2, color=:mediumaquamarine, label="t Student")
hist!(ax, x2, color=:red, normalization=:pdf, label="t Student")
axislegend(ax)
button = Button(fig[2, 1:2], label="Tomar Nueva Muestra")
```

```

l = on(button.clicks) do b
    t[] = sample(1:length(X1[]), N[])
    x1[] = X1[][t[]]
    x2[] = X2[][t[]]
    df = N[] - 1
end
fig

```




Figure 8: Comparación entre la Distribución Normal y la Distribución t de Student

0.7 Distribución Log-Normal

La distribución log-normal es una distribución de probabilidad continua que se utiliza para modelar variables aleatorias que son el resultado de la multiplicación de varias variables aleatorias independientes. La distribución log-normal tiene dos parámetros: la media y la desviación estándar de la variable logarítmica.

$$f(x|\mu, \sigma) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{(\ln(x)-\mu)^2}{2\sigma^2}}$$

```

U = 10000
N = 10
= Observable(0.0)
= Observable(1.0)
X = Observable(rand(LogNormal( [], []), U))
t = Observable(sample(1:length(X[]), N))
x = Observable(X[][t[]])
fig = Figure(size=(1600, 600));

```

```

ax = Axis(fig[1, 1], subtitle="Muestra de Población")
scatter!(ax, X, color=:mediumaquamarine)
scatter!(ax, t, x, color=:lightcoral, marker=:xcross, markersize=20)
ax = Axis(fig[1, 2], subtitle="Distribución")
density!(ax, X, color=:mediumaquamarine)
hist!(ax, x, color=:lightcoral, normalization=:pdf)
sg = SliderGrid(fig[2,1],
    (label=" ", range=0:0.01:3, format="{:.2f}", startvalue=0.0),
    (label=" ", range=0.1:0.01:1, format="{:.2f}", startvalue=1.0),
)
sliderobservables = [s.value for s in sg.sliders]
bars = lift(sliderobservables...) do ,
    X[] = rand(LogNormal( , ), U)
    t[] = sample(1:length(X[]), N)
    x[] = X[][t[]]
    println("Estadísticas Descriptivas de la Muestra:")
    println("Media: ", mean(x[]))
    println("Mediana: ", median(x[]))
    println("Desviación Estándar: ", std(x[]))
end
fig

```

Estadísticas Descriptivas de la Muestra:
 Media: 1.7832910335352892
 Mediana: 1.3052851841818143
 Desviación Estándar: 1.434110180643464




Figure 9: Distribución de Log-Normal

Distribución sintética para tres valores de μ :




Figure 10: Parámetros de la Distribución Log-Normal

0.8 Pruebas de Hipótesis

Una prueba de hipótesis es un procedimiento estadístico que se utiliza para tomar una decisión sobre una afirmación acerca de un parámetro de una población. La afirmación que se está probando se llama hipótesis nula (H_0) y la afirmación alternativa se llama hipótesis alternativa (H_1). La prueba de hipótesis se basa en la probabilidad de obtener un resultado tan extremo como el observado, si la hipótesis nula es verdadera. Si la probabilidad es baja, se rechaza la hipótesis nula.

```
U = 100000
N = 1000
1 = Observable(0.0)
1 = Observable(1.0)

2 = Observable(0.0)
2 = Observable(1.0)

3 = sum([ 1[], 2[]])
3 = sqrt( 1[]^2 + 2[]^2)

x = range(-10, 10, length=U)
y1 = Observable(pdf(Normal( 1[], 1[]), x))
y2 = Observable(pdf(Normal( 2[], 2[]), x))
# y3 = Observable(pdf(Normal( 3[], 3[]), x))
= Observable([quantile(Normal( 1[], 1[]), 0.95)])
```

```

    = Observable([quantile(Normal( 2[], 2[]), 0.20)])
p = Observable(pvalue(SignedRankTest(y1[], y2[])))

fig = Figure(size=(1600, 600));
ax = Axis(fig[1, 1])
l1 = lines!(ax, x, y1, color=:teal, linewidth=10)
l2 = lines!(ax, x, y2, color=:coral, linewidth=10)
# l3 = lines!(ax, x, y3, color=:orchid, linewidth=10)
l = vlines!(ax, , color=:black, linestyle=:dash, linewidth=1)
l = vlines!(ax, , color=:red, linestyle=:dash, linewidth=1)
Legend(fig[1, 2], [l1, l2, l, l], ["H0", "H1", "p=0.05", "Power=.80"])
lab = Label(fig[2, 2], "p=$(round(p[], digits=4))")
fig

# SliderGrid
sg = SliderGrid(fig[2,1],
    (label=" 1", range=-5:0.1:5, format="{:.2f}", startvalue=0.0),
    (label=" 1", range=0.1:0.1:5, format="{:.2f}", startvalue=1.0),
    (label=" 2", range=-5:0.1:5, format="{:.2f}", startvalue=0.0),
    (label=" 2", range=0.1:0.1:5, format="{:.2f}", startvalue=1.0),
    (label="N", range=10:10:U, format="{:.0f}", startvalue=N),
)
sliderobservables = [s.value for s in sg.sliders]
bars = lift(sliderobservables...) do 1, 1, 2, 2, N
    # 3 = 1 + 2
    # 3 = sqrt(1^2 + 2^2)
    y1[] = pdf(Normal( 1, 1), x)
    y2[] = pdf(Normal( 2, 2), x)
    # y3[] = pdf(Normal( 3, 3), x)
    [] = [quantile(Normal( 1, 1), 0.95)]
    [] = [quantile(Normal( 2, 2), 0.20)]
    p[] = pvalue(SignedRankTest(sample(y1[], N), sample(y2[], N)))
    lab.text[] = "p*=$(round(p[], digits=4))"
end

fig

```