

# Onboarding Neurociencias LaSalle Bajío

Alberto Barradas

# Temario

- Variables y Procesos Aleatorios
- Muestreo y Distribución Probabilística
- Estadísticas Descriptivas
- Esquema de Tests de Hipótesis
- Modelado y variables latentes
- Modelos Jerarquicos o Mixtos
- Probabilidad Condicional
- Teorema de Bayes
- Actualización de creencias con base en evidencias
- Tests bayesianos de hipótesis, Factor de Bayes, y JASP
- Meta-Ciencia, Ética, Bibliometría, SNA, PM, KM, Mindfulness and Cognitive Flexibility


# Variable Aleatoria

En Probabilidad y Estadística, una variable aleatoria es **una función que asigna un valor numérico al resultado de un experimento aleatorio.**

La variable no tiene un solo valor numérico, sino que puede tomar varios valores numéricos, cada uno con una cierta probabilidad.

Una forma de describir esa probabilidad es mediante una función de probabilidad, que asigna a cada valor numérico posible de la variable aleatoria una probabilidad.

► Code



Variable Algebraica vs Aleatoria

## Ejemplos:

- El número de caras que aparecen al lanzar una moneda 3 veces.
- La cantidad de tiempo que un estudiante tarda en completar un examen.
- La cantidad de veces que un estudiante se enferma durante un año.
- La presencia o ausencia de un comportamiento específico en distintas personas.

# Definiciones

Para distinguir una variable algebraica de una variable aleatoria, se suele utilizar letras mayúsculas para las variables aleatorias y letras minúsculas para las variables algebraicas.

Por ejemplo, si  $X$  es una variable aleatoria,  $x$  es un valor posible de  $X$ . Y la probabilidad de que  $X$  tome el valor  $x$  se denota como  $P(X = x)$ .


**Ejemplo:** La variable  $X$  que representa las probabilidades de los valores de un tiro de dado, puede presentar seis distintos valores: 1, 2, 3, 4, 5, 6.

La probabilidad de que  $X$  tome el valor 1 es  $P(X = 1) = 1/6$ .

# Visualización de una variable aleatoria

## Animación

► Code




Variable Aleatoria

# Muestreo

Generalmente no es posible estudiar cada posible probabilidad de cada valor de una variable aleatoria, por lo que se puede tomar una muestra de la población para su estudio.

A las funciones que nos permiten agregar información de una muestra a la población se les llama Estadísticas.

► Code



Muestreo de una población

## Ejemplo:

- La media de una muestra de una población  $\bar{x}$  se puede utilizar para estimar la media de la población  $\mu$ .
- Lo mismo se puede hacer con la varianza, la moda, el rango, la mediana, la correlación, la covarianza, etc.

## Definiciones:

- **Población:** Conjunto de todos los elementos de interés. (Universo: U)
- **Muestra:** Subconjunto de la población. (N)




## Ejemplo:

Tomamos una muestra de 20 personas de una población de 100,000 estudiantes entre 18 y 30 años en México. Se extrae una estadística de la muestra para estimar la media de la población. Esa estadística será representativa, en medida de que la muestra sea representativa de la población.

Pregunta: ¿Cómo se puede saber si una muestra es representativa de la población? Generalmente se utiliza el muestreo aleatorio simple, donde cada elemento de la población tiene la misma probabilidad de ser seleccionado.

# Visualización de muestreo

► Code



Muestreo de una población


# Distribución de Probabilidad

Hemos utilizado distribuciones uniformes, como las de aventar un dado. Estas variables aleatorias pueden tomar cualquiera de sus valores con la misma probabilidad, pero esto no tiene que ser así. Si un dado está cargado, la probabilidad de que salgan ciertos números es mayor que otros.

Una distribución de probabilidad describe cómo se distribuyen los valores de una variable aleatoria y la probabilidad de que la variable aleatoria tome un valor específico.

Recomendamos que memoricen dos distribuciones de probabilidad con sus parámetros:

► Code




# Distribuciones de Probabilidad



# Distribución uniforme

El ejemplo más común cuando se habla de una distribución aleatoria es la distribución uniforme. En una distribución uniforme, todos los valores posibles de la variable aleatoria tienen la misma probabilidad de ocurrir. Por ejemplo, si lanzamos un dado, la probabilidad de que salga un 1, 2, 3, 4, 5 o 6 es la misma.

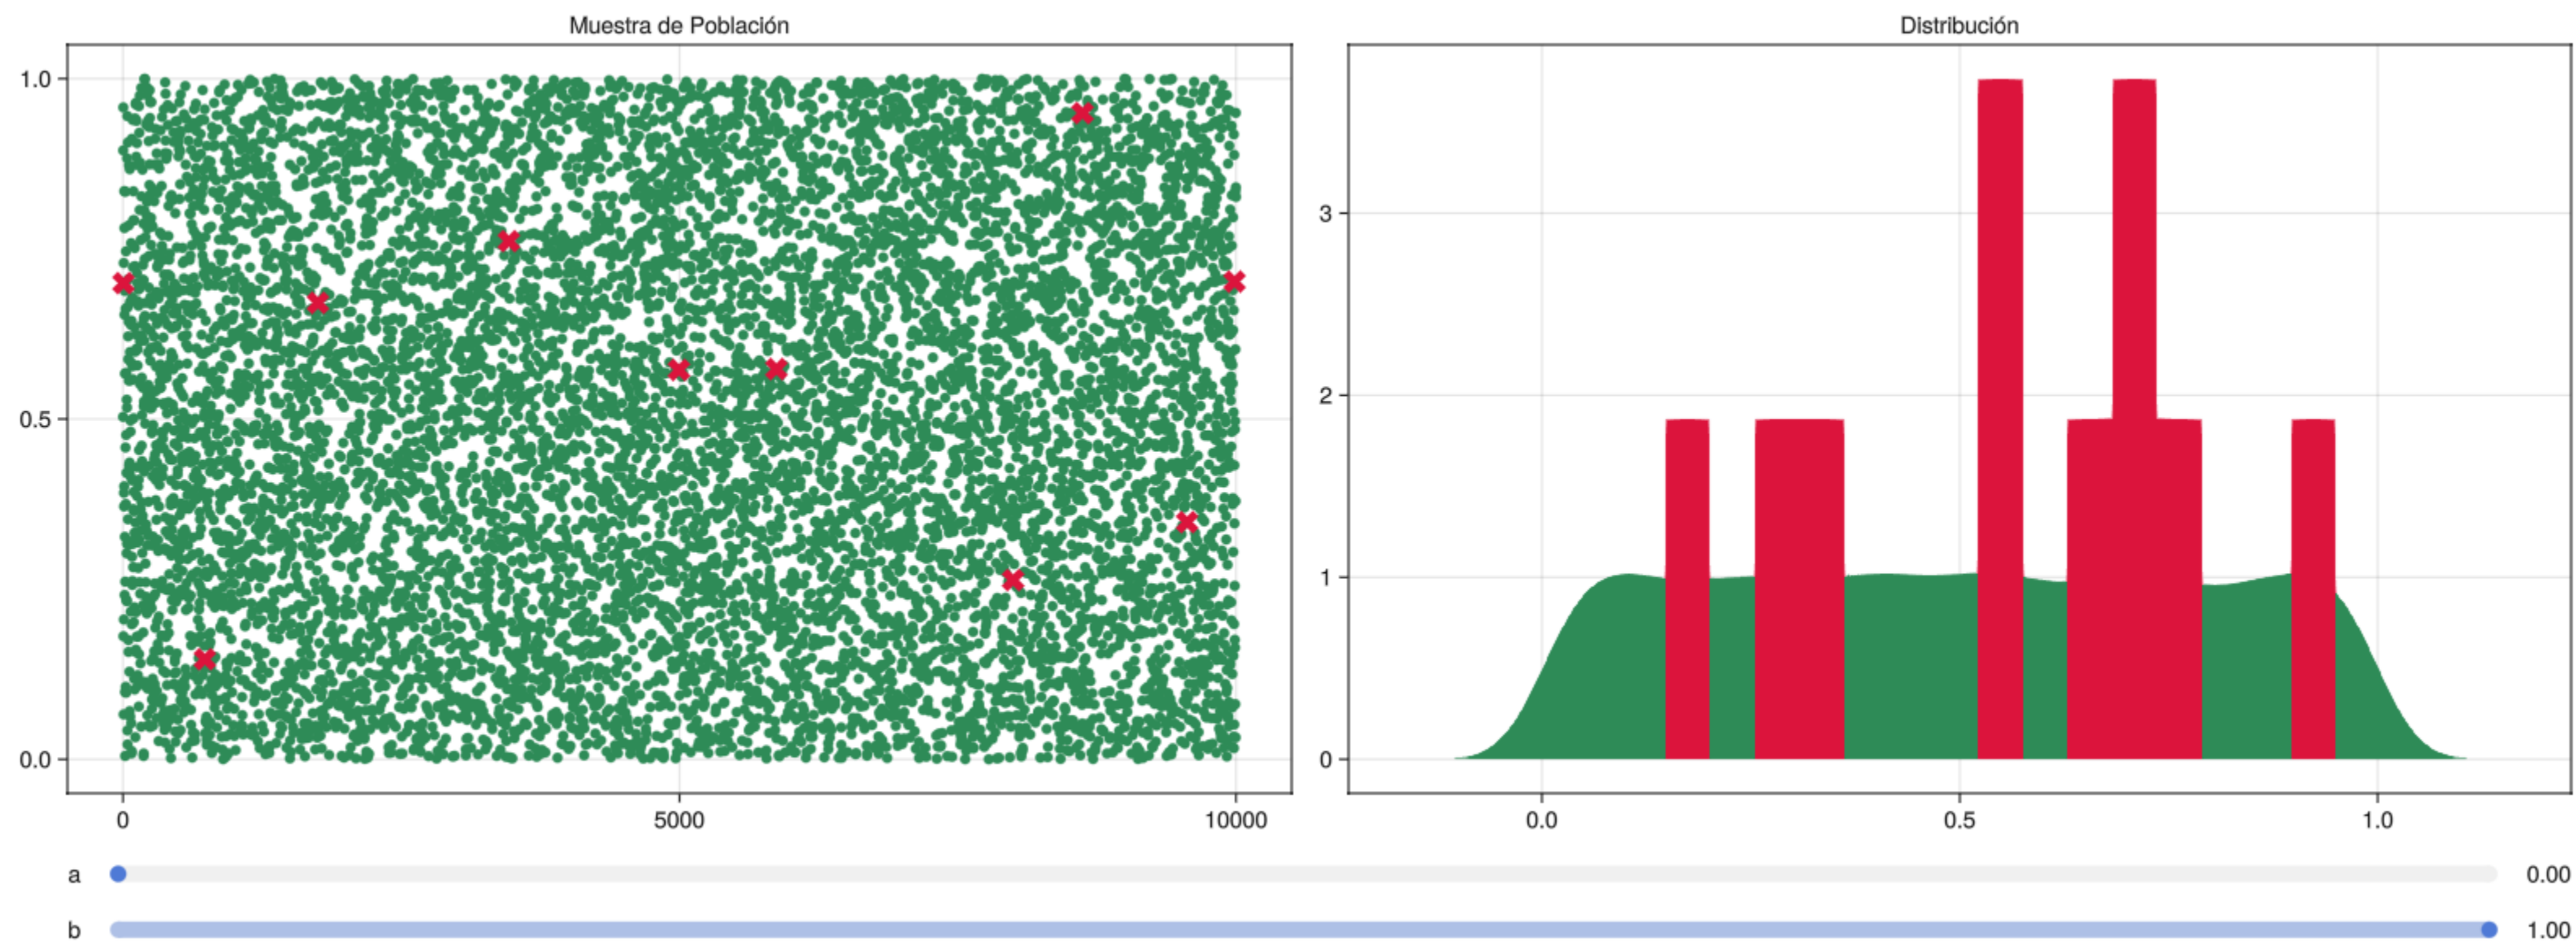
► Code



Distribución Uniforme

Una distribución uniforme puede ser completamente descrita por dos parametros:  $a$  y  $b$ , que representan el rango de valores posibles de la variable aleatoria. Cambiando los valores de  $a$  y  $b$ , podemos cambiar la forma de la distribución:

► Code




Parámetros de la Distribución Uniforme



# Distribución normal

No todas las distribuciones aleatorias tienen la misma probabilidad de ocurrencia. La distribución normal es una de las distribuciones más comunes en estadística: es simétrica y tiene una forma de campana. También es una distribución continua, lo que significa que puede tomar cualquier valor en un rango continuo.


► Code



Distribucion Normal

La distribución normal puede ser descrita por dos parametros:  $\mu$  y  $\sigma$ , que representan la media y la desviación estándar de la distribución. Cambiando los valores de  $\mu$  y  $\sigma$ , podemos cambiar la forma de la distribución:

► Code



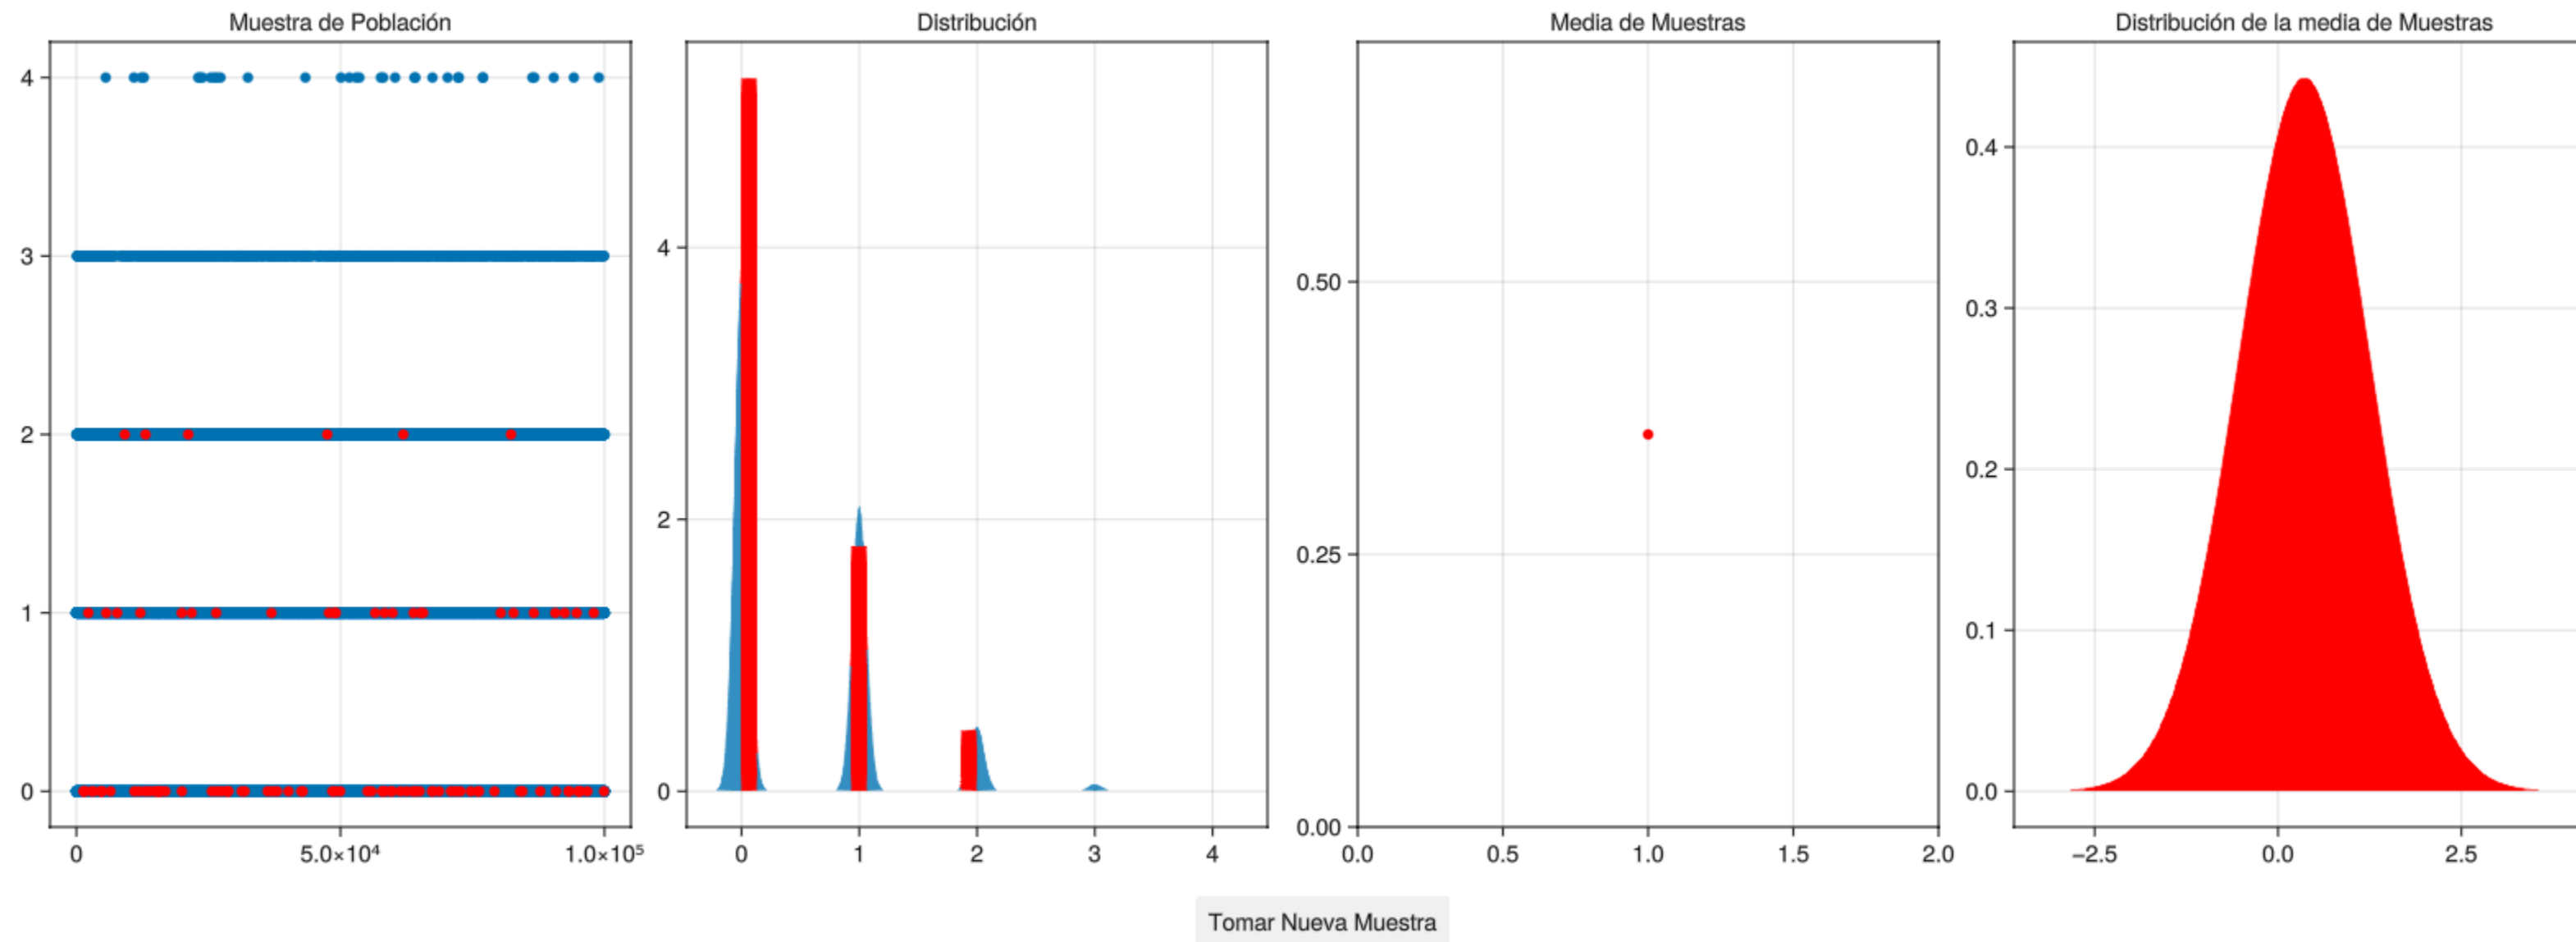
Parámetros de la Distribución Normal



# Estadísticas Descriptivas

Las estadísticas descriptivas son métodos para resumir, organizar y visualizar datos. Estas estadísticas se pueden utilizar para describir las características de los datos y para resumir la información contenida en un conjunto de datos.

## ► Code




Estadísticas Descriptivas

# Pruebas de Hipótesis

Una prueba de hipótesis es un procedimiento estadístico que se utiliza para tomar una decisión sobre una afirmación acerca de un parámetro de una población. La afirmación que se está probando se llama hipótesis nula ( $H_0$ ) y la afirmación alternativa se llama hipótesis alternativa ( $H_1$ ). La prueba de hipótesis se basa en la probabilidad de obtener un resultado tan extremo como el observado, si la hipótesis nula es verdadera. Si la probabilidad es baja, se rechaza la hipótesis nula.

## ► Code



# Problemas de reproducibilidad en ciencias cognitivas

- The Open Science Collaboration (2015) <https://osf.io/82fth>: 36% de los estudios replicados tuvieron resultados significativos, comparado con 97% de los estudios originales. Collaboration (2015)

The Many Labs Project (2014) <https://osf.io/wx7ck/>: 10 de 13 estudios replicados tuvieron resultados significativos, comparado con 13 de 13 estudios originales. Klein et al. (2013)



# Prácticas cuestionables en investigación

John, L. K., Loewenstein, G., & Prelec, D. (2012). Measuring the prevalence of questionable research practices with incentives for truth telling. *Psychological science*, 23(5), 524-532. [<https://www.cmu.edu/dietrich/sds/docs/loewenstein/MeasPrevalQuestTruthTelling.pdf>] John, Loewenstein, and Prelec (2012)

1. In a paper, failing to report all of a study's dependent measures.
2. Deciding whether to collect more data after looking to see whether the results were significant.
3. In a paper, failing to report all of a study's conditions.
4. Stopping collecting data earlier than planned because one found the result that one had been looking for.
5. In a paper, “rounding off” a p value (e.g., reporting that a p value of .054 is less than .05).
6. In a paper, selectively reporting studies that “worked”.
7. Deciding whether to exclude data after looking at the impact of doing so on the results.
8. In a paper, reporting an unexpected finding as having been predicted from the start.
9. In a paper, claiming that results are unaffected by demographic variables (e.g., gender) when one is actually unsure (or knows that they do).
10. Falsifying data.

# Modelado y Variables latentes

Cuando los verdaderos parametros de una población no son observables, se pueden utilizar variables latentes para describir el comportamiento verdadero de la población. Estas son variables que no se pueden observar directamente, pero que se pueden inferir a partir de evidencias. Esta forma de pensar nos permite conceptualizar cada experimento: no como eventos independientes, sino como un muestreo de una variable latente. Así, cada nuevo experimento produce evidencia en contra o a favor de nuestras creencias sobre los parametros que describen la distribución de la población. A esto le llamamos modelado estadístico.




Este tipo de modelado requiere el manejo explícito de creencias sobre las distribuciones de parametros en la población a estudiar. También nos permite modelar otras posibles variables ocultas (o de confusión) que puedan influir en los resultados de nuestros experimentos.

# Ejercicio

Hagamos un ejercicio para desarrollar intuición. Infiera la distribución de la que provienen las siguientes muestras:

► Code




## Modelado y Variables Latentes

### Solución

```
Gamma{Float64} (α=2.0, θ=1.0)
```

# Modelos Jerarquicos

Así como podemos inferir la distribución de una variable aleatoria a partir de una muestra, también podemos inferir la distribución de los parametros de una distribución a partir de una muestra. A esto se le llama inferencia jerarquica. Aqui los parametros de una distribución son variables aleatorias que siguen una distribución. Este tipo de modelado nos permite inferir la distribución de los parametros de una distribución a partir de una muestra, y nos permite modelar la incertidumbre en nuestras creencias sobre los parametros de una distribución.



A su vez, estos parametros pueden representar variabilidad entre grupos de muestras. Por ejemplo, si tomamos muestras de dos poblaciones distintas, podemos inferir la distribución de los parametros de cada población, y la variabilidad entre las poblaciones. A esto se le conoce también como modelos mixtos. Estos son el estandard de oro en la inferencia estadística. Prof. Nan Laird obtuvo el premio internacional de estadística por su descripción de estos modelos ([Laird 2004](#)).

# Probabilidad Condicional

Como hemos visto, no todos los eventos son independientes. La probabilidad de que ocurra un evento puede depender de que ocurra otro evento. A esto se le llama probabilidad condicional. La probabilidad de que ocurra un evento A dado que ocurra un evento B se denota como  $P(A|B)$ . La probabilidad condicional se puede calcular como el cociente de la probabilidad conjunta de  $A$  y  $B$  entre la probabilidad de  $B$ .  $P(A|B) = P(A \cap B) / P(B)$ .

## Definiciones:

- **Independencia:** Dos eventos son independientes si la probabilidad de que ocurra uno no depende de que ocurra el otro.  $P(A|B) = P(A)$ .
- **Dependencia:** Dos eventos son dependientes si la probabilidad de que ocurra uno depende de que ocurra el otro.  $P(A|B) \neq P(A)$ .
- **Probabilidad Conjunta:** La probabilidad de que ocurran dos eventos simultáneamente.  $P(A \cap B)$ .
- **Probabilidad Marginal:** La probabilidad de que ocurra un evento sin importar si ocurre otro evento.  $P(A)$ .



## Ejemplo:

La probabilidad de que un estudiante apruebe un examen de matemáticas es de 0.7. La probabilidad de que un estudiante apruebe un examen de matemáticas y física es de 0.5. La probabilidad de que un estudiante apruebe un examen de física es de 0.6. ¿Cuál es la probabilidad de que un estudiante apruebe un examen de matemáticas dado que aprobó un examen de física?

### Solución

- $P(A) = 0.7$
- $P(A \cap B) = 0.5$
- $P(B) = 0.6$
- $P(A|B) = P(A \cap B) / P(B) = 0.5 / 0.6 = 0.8333$

# Teorema de Bayes

El teorema de Bayes es una regla para actualizar creencias con base en evidencias. Nos permite calcular la probabilidad de una hipótesis dada una evidencia. La probabilidad de una hipótesis  $(H)$  dado un conjunto de evidencias  $(E)$  se puede calcular como el producto de la probabilidad de la evidencia dado la hipótesis  $(P(E|H))$  por la probabilidad de la hipótesis  $(P(H))$  dividido por la probabilidad de la evidencia  $(P(E))$ .  $P(H|E) = P(E|H) * P(H) / P(E)$ .

VisualBayes

$$P(H|E) = \frac{P(E|H) * P(H)}{P(E)} = \frac{P(E|H) * P(H)}{P(E|H) * P(H) + P(E|\neg H) * P(\neg H)}$$

## Ejemplo 1

Sabemos que la probabilidad de que un estudiante de cierta escuela tenga TDA es del 0.1. También sabemos que la proporción de hombres y mujeres es del 50%. También sabemos que entre los estudiantes diagnosticados con TDA, el 60% son hombres. ¿Cuál es la probabilidad de que un estudiante tenga TDA dado que es hombre?

## Solución

$(P(A) = 0.1)$  es la probabilidad de que un estudiante tenga TDA.  $(P(B) = 0.5)$  es la probabilidad de que un estudiante sea hombre.  $(P(B|A) = 0.6)$  es la probabilidad de hombres entre los estudiantes con TDA.

Para encontrar  $(P(A | B))$ , primero necesitamos calcular  $(P(B | A))$  y  $(P(B))$  como se ha dado, y luego encontrar  $(P(A \cap B))$  usando la fórmula de probabilidad condicional. Esta es la probabilidad de que un estudiante en esa escuela tenga TDA Y sea Hombre.  $[ P(A \cap B) = P(B|A) * P(A) = 0.6 * 0.1 = 0.06 ]$

Por lo tanto, la probabilidad de que un estudiante tenga TDA dado que es hombre es:

### Tip

$$[ P(A|B) = P(A \cap B) / P(B) = 0.06 / 0.5 = 0.12 ]$$

## Ejemplo 2

Hicimos un experimento, en el que el 30% de nuestros participantes reportaron reportaron dormir mal. Sabemos que el 50% de las personas que reportaron dormir mal, también reportaron tener ansiedad. También sabemos que el 20% de las personas que no reportaron dormir mal, reportaron tener ansiedad. ¿Cuál es la probabilidad de que una persona tenga ansiedad dado que reportó dormir mal?

### Tip

#### Solución:

- $(P(D) = 0.3)$
- $(P(\neg D) = 0.7)$
- $(P(A|D) = 0.5)$
- $(P(A|\neg D) = 0.2)$
- $(P(A \cap D) = P(A|D) * P(D) = 0.5 * 0.3 = 0.15)$
- $(P(A \cap \neg D) = P(A|\neg D) * P(\neg D) = 0.2 * 0.7 = 0.14)$
- $(P(A) = P(A \cap D) + P(A \cap \neg D) = 0.15 + 0.14 = 0.29)$
- $(P(D|A) = P(A|D) * P(D) / P(A) = 0.5 * 0.3 / 0.29 = 0.5172)$

## Ejemplo 3

Un laboratorio produce pruebas de detección de un trastorno. La prueba tiene una sensibilidad del 99% y una especificidad del 95%. La enfermedad afecta al 1% de la población. ¿Cuál es la probabilidad de que una persona tenga la enfermedad dado que la prueba dio positivo?

**Solución:** La sensibilidad se refiere a la probabilidad de que la prueba sea positiva dado que la persona tiene la enfermedad. La especificidad se refiere a la probabilidad de que la prueba sea negativa dado que la persona no tiene la enfermedad. Ambas se pueden obtener de una matriz de confusión, y describen completamente el desempeño de una prueba de detección.

	Enfermo	Sano
Positivo	TP	FP
Negativo	FN	TN

En este caso:

%	Enfermo	Sano
+	0.99	0.05
-	0.01	0.95

Tip

- $P(D) = 0.01$
- $P(\neg D) = 0.99$
- $P(+) = P(+|D) * P(D) + P(+|\neg D) * P(\neg D) = 0.99 * 0.01 + 0.05 * 0.99 = 0.0585$
- $P(D|+) = P(+|D) * P(D) / P(+) = 0.99 * 0.01 / 0.0585 = 0.1684$

# Más material

Para desarrollar una intuición sobre el teorema de Bayes, sugiero los videos de Grant Sanderson en 3Blue1Brown:

- [Bayes Theorem](#)
- [Bayes Theorem Proof](#)
- [Bayes Theorem Examples](#)



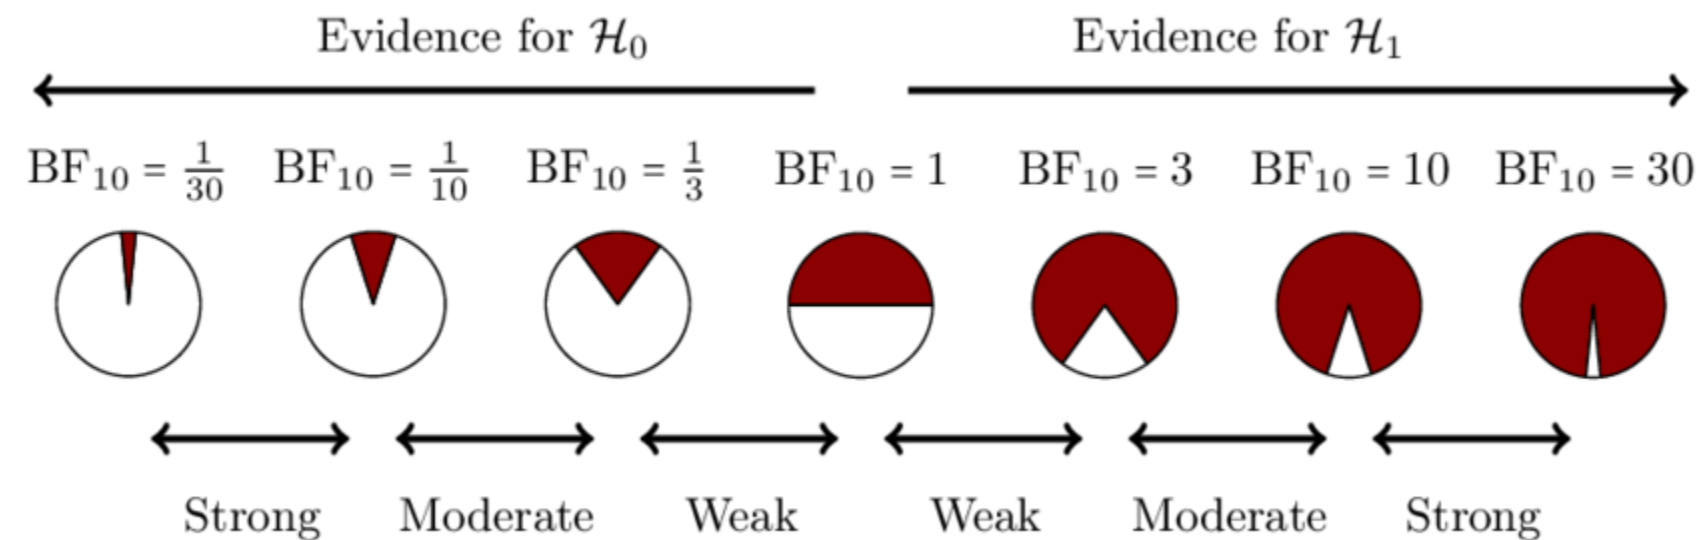
# Actualización de creencias con base en evidencias

Como pueden ver, el teorema de Bayes nos permite actualizar nuestras creencias con base en evidencias. A diferencia de un test de hipótesis, donde nuestra  $N$  debe ser muy bien definida, con el teorema de Bayes podemos actualizar nuestras creencias con base en cada nueva evidencia que obtenemos. A medida que obtenemos más evidencias, nuestras creencias y certidumbre sobre ellas se refinan. Esto es lo que se conoce como inferencia bayesiana. En la inferencia bayesiana, las creencias se representan como distribuciones de probabilidad.

[BeliefUpdate](#)

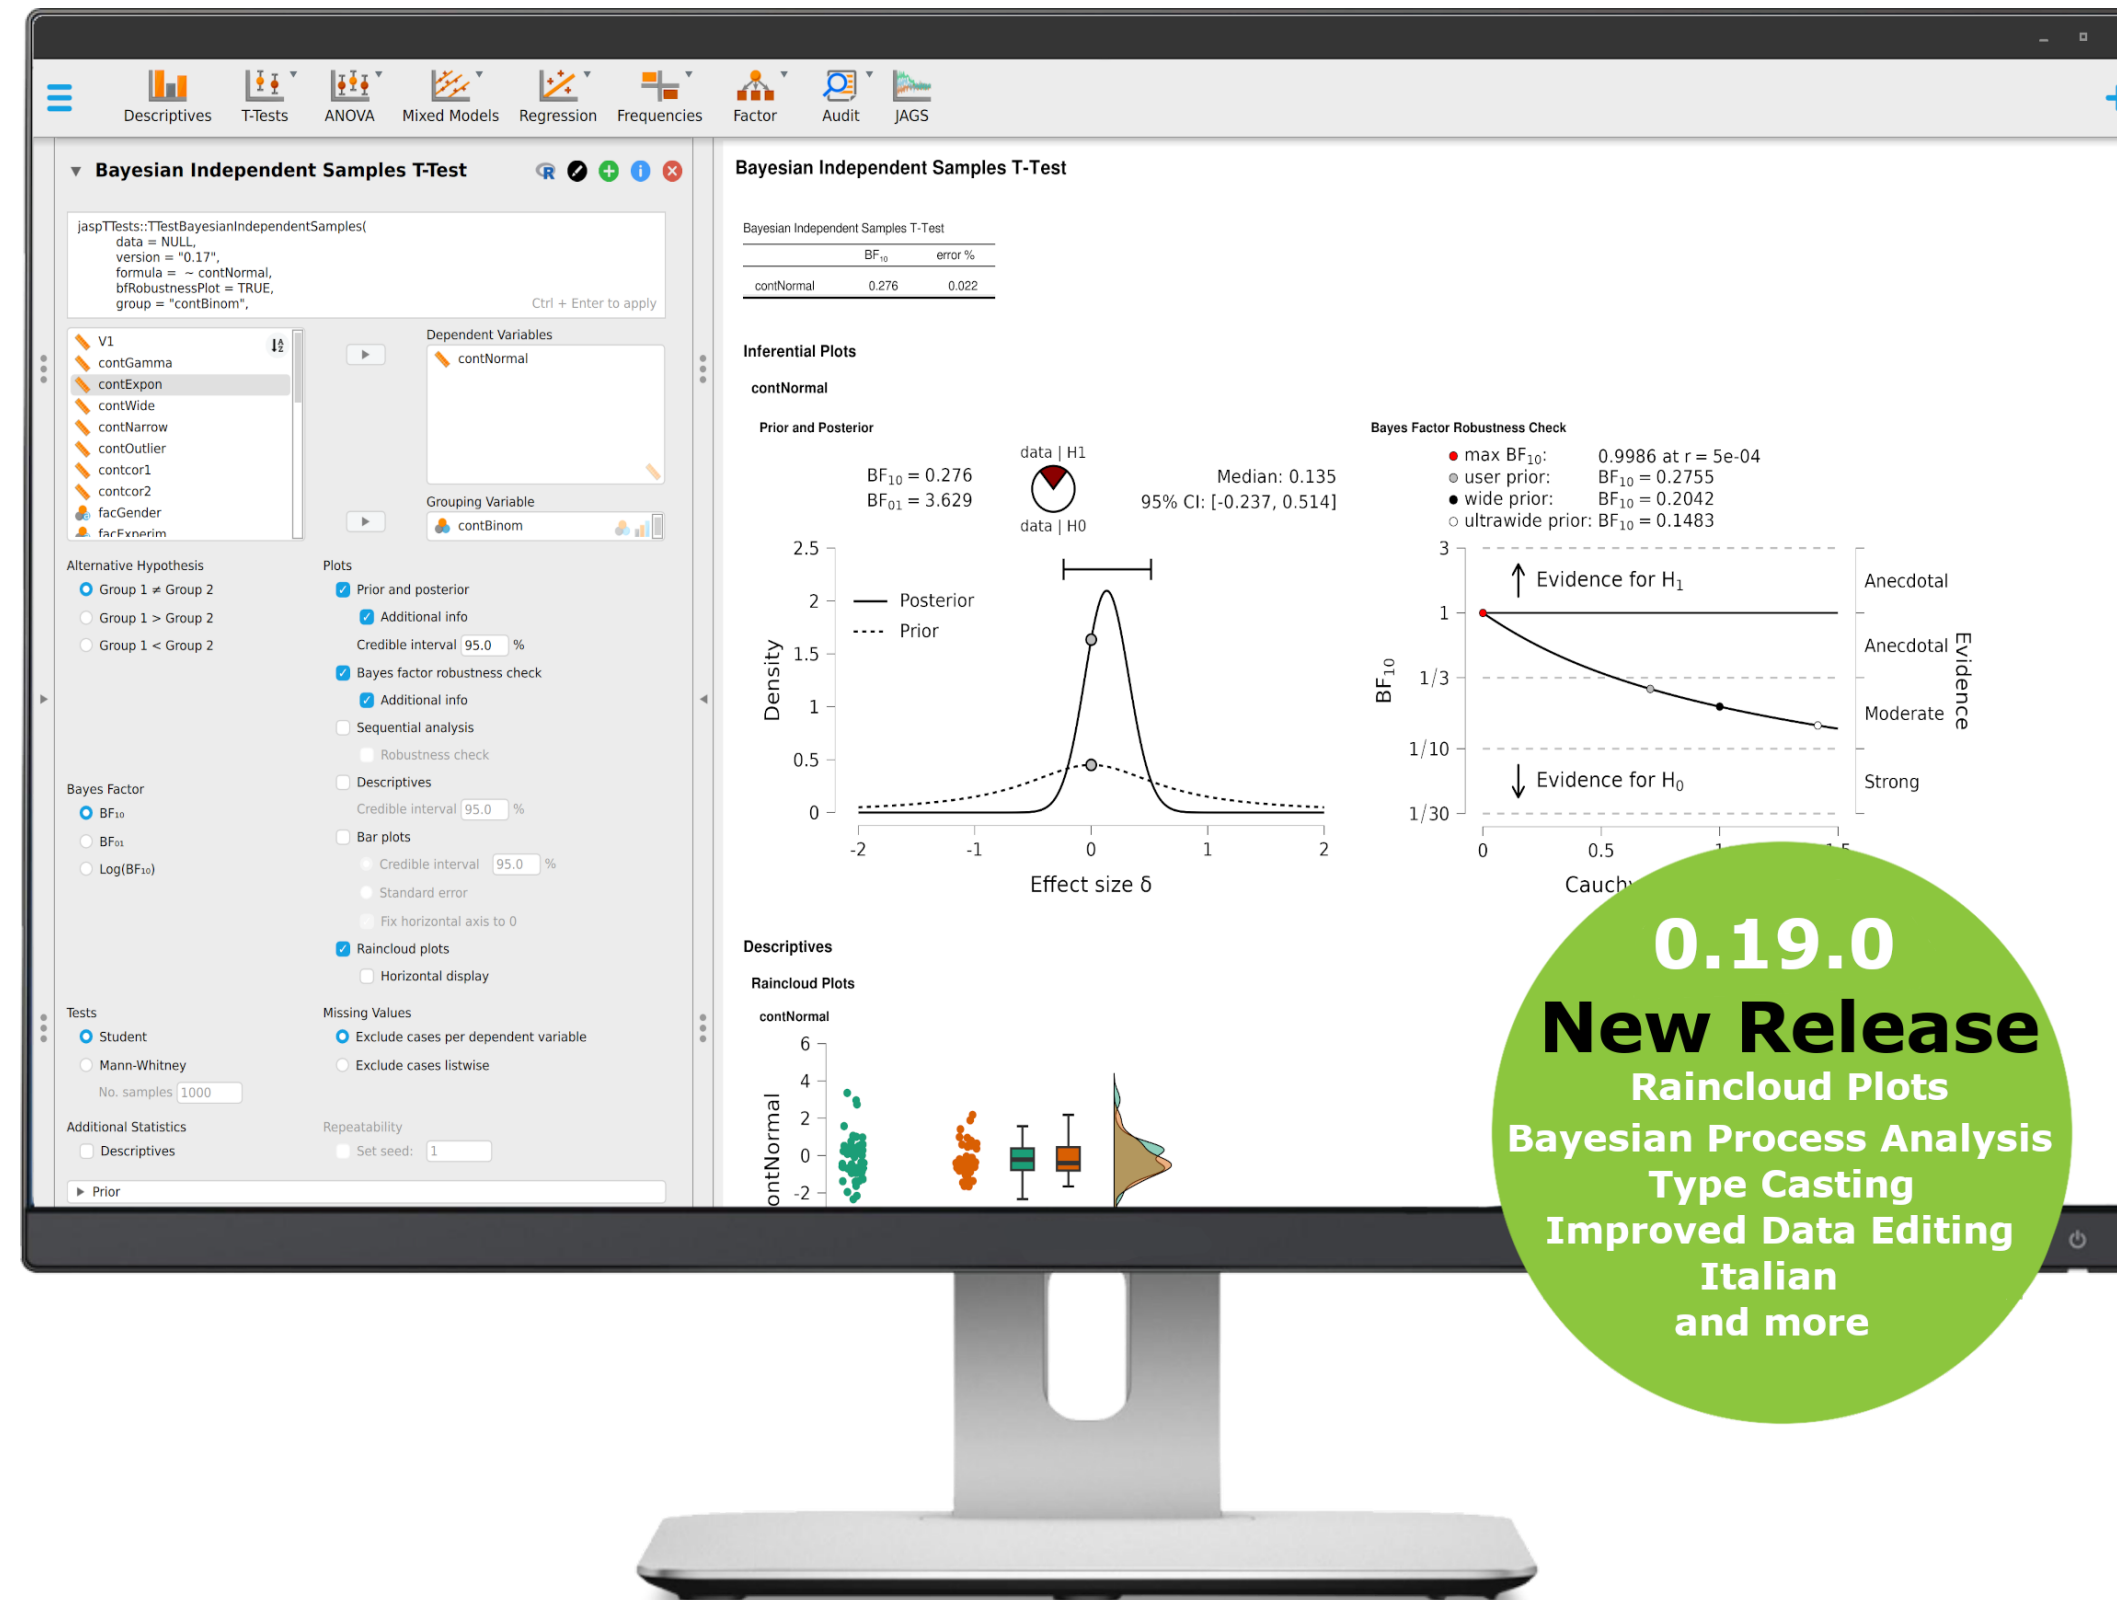
# Tests bayesianos de hipótesis

El marco de test de hipótesis no excluye el análisis bayesiano. De hecho, el test de hipótesis es un caso especial de inferencia bayesiana. En el test de hipótesis, se calcula la probabilidad de obtener un resultado tan extremo como el observado, si la hipótesis nula es verdadera. En la inferencia bayesiana, se calcula la probabilidad de que la hipótesis nula sea verdadera dado el resultado observado. A esto se le conoce como factor de Bayes. Si el factor de Bayes es mayor a 1, la hipótesis nula es más probable. Si el factor de Bayes es menor a 1, la hipótesis nula es menos probable.



([Van Doorn et al. 2021](#))

# Herramientas



JASP

La herramienta que utilizamos para hacer estos tests es JASP. JASP es un software de código abierto, desarrollado por la Universidad de Amsterdam, que permite hacer análisis bayesianos de forma sencilla. Pueden descargarlo de [aquí](#).

# Meta-Ciencia

El método científico se puede aplicar a la ciencia misma. Lo que llamamos meta-ciencia es el proceso de analizar los métodos y prácticas del laboratorio a través de **análisis estructurado y crítico**. Aunado a la inferencia bayesiana, existen otras herramientas que nos permitirán mantener un manejo **explícito** de nuestros conocimientos científicos.

Lectura sugerida: Hofstadter ([1999](#)).

**Pregunta:** ¿Cuál es el rol del científico en la sociedad?

# Manejo y gestion del Conocimiento

El manejo del conocimiento es el proceso de adquirir, almacenar, compartir y utilizar el conocimiento. El conocimiento es un **activo intangible** que puede ser difícil de cuantificar y medir.

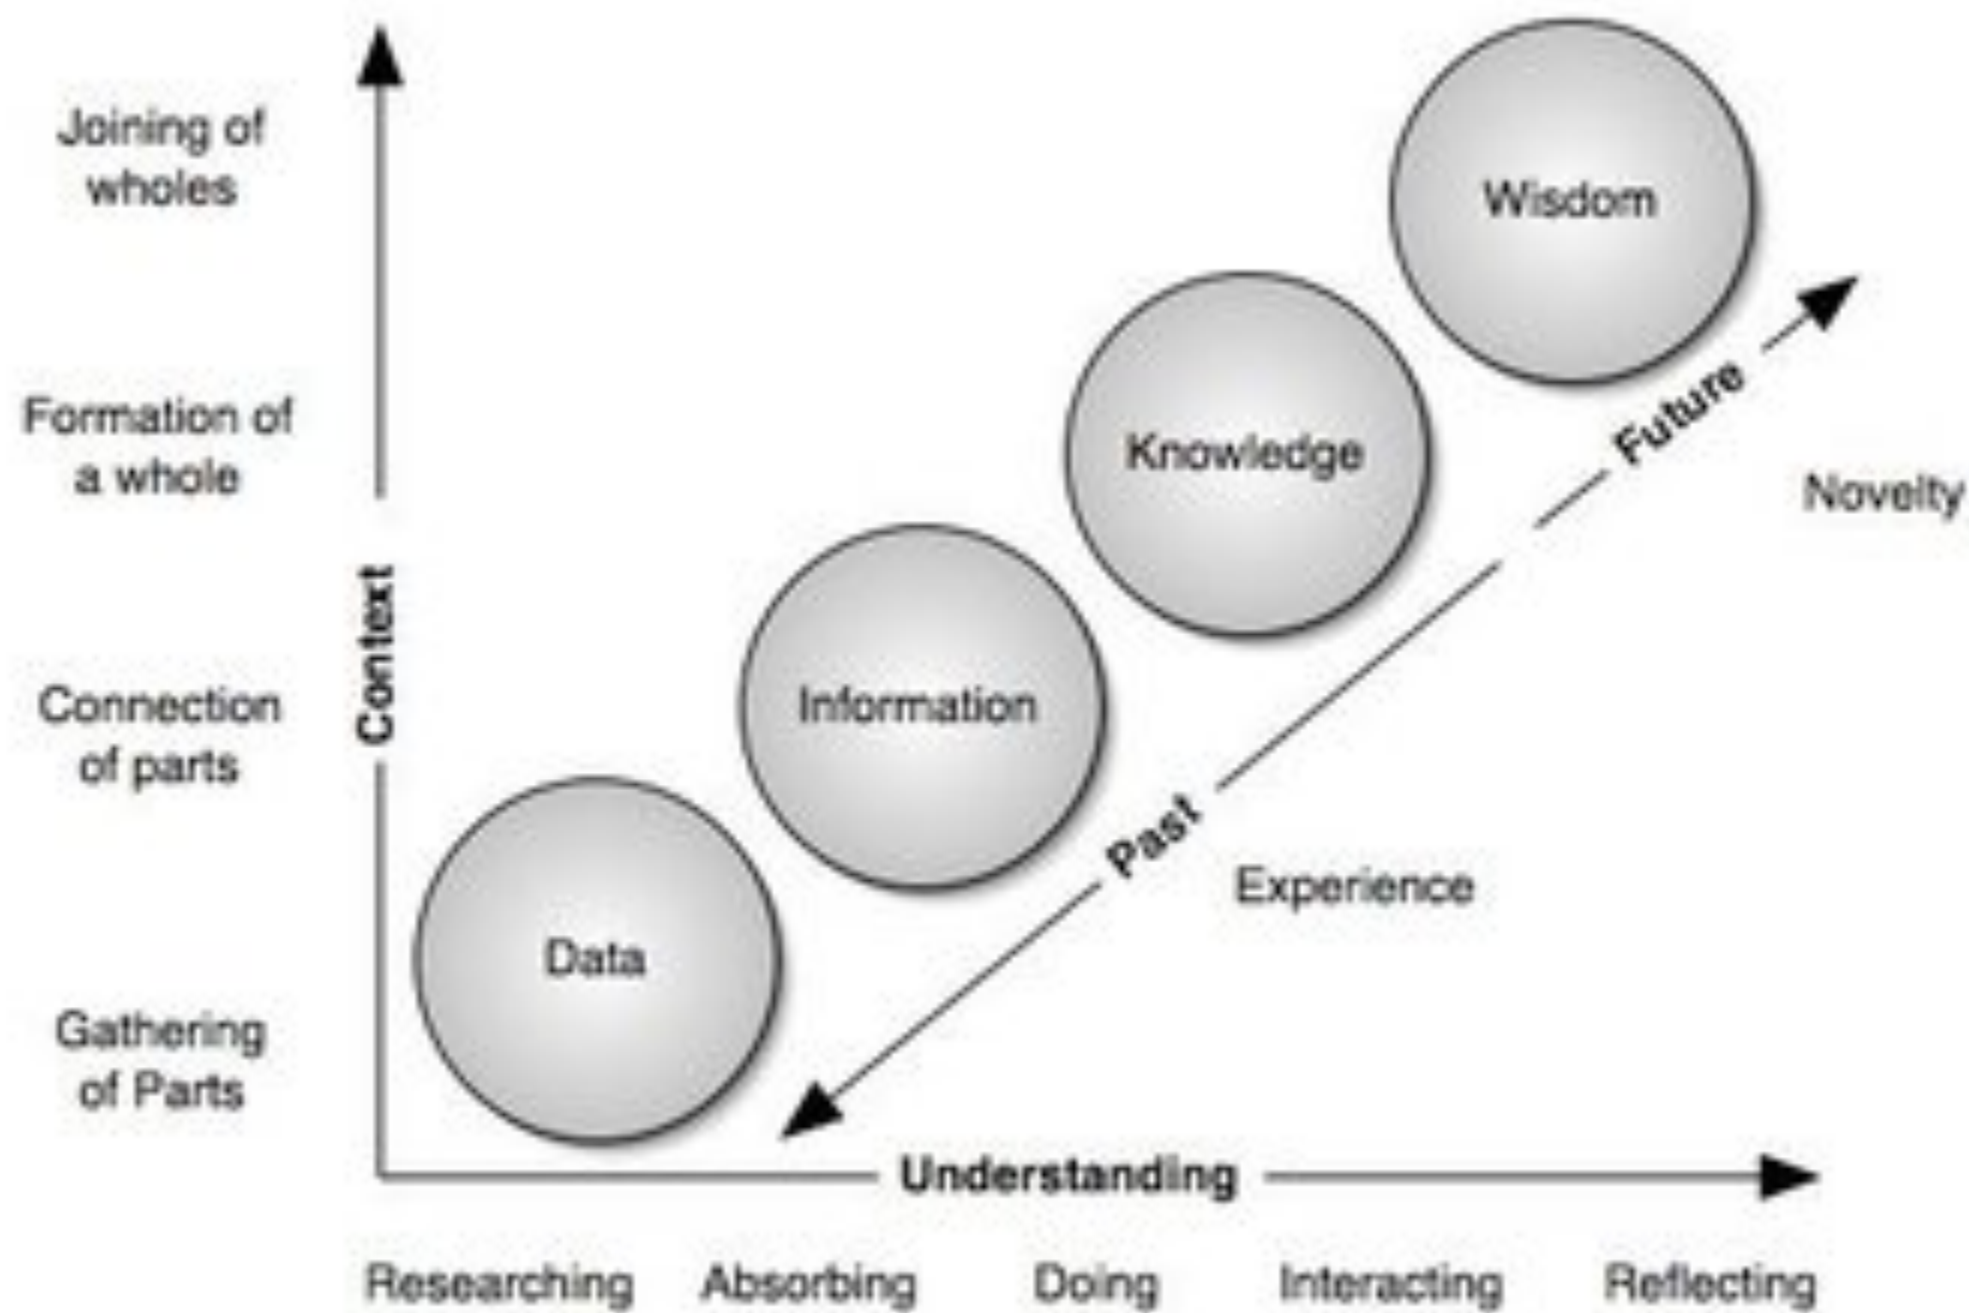
## Definiciones:

- Conocimiento Tácito (Implicito): Conocimiento que no se puede expresar en palabras, pero se puede demostrar a través de acciones.
- Conocimiento Explicito: Conocimiento que se puede expresar en palabras y se puede compartir con otros.
- Institución: Conjunto de creencias que se expresan en el comportamiento de un grupo de personas.
- Conocimiento institucionalizado: Conocimiento que se ha convertido en parte de la estructura de una organización.
- Conocimiento tácito institucional: Conocimiento institucional que no se puede expresar en palabras.

**Pregunta:** ¿De que formas explicitas se maneja el conocimiento científico? ¿Qué formas implícitas de conocimiento científico conocen?

# Pirámide del conocimiento

La pirámide del conocimiento es una representación visual de la jerarquía del conocimiento.



DIKW

Img: Flood et al. (2016)

# Sesgos Cognitivos

El pensamiento humano falla comunmente de formas predecibles y sistemáticas. A estos fallos sistemáticos del pensamiento se les conoce como sesgos cognitivos. Los sesgos cognitivos pueden afectar la toma de decisiones y la interpretación de la información. Algunos de los sesgos cognitivos más comunes son:

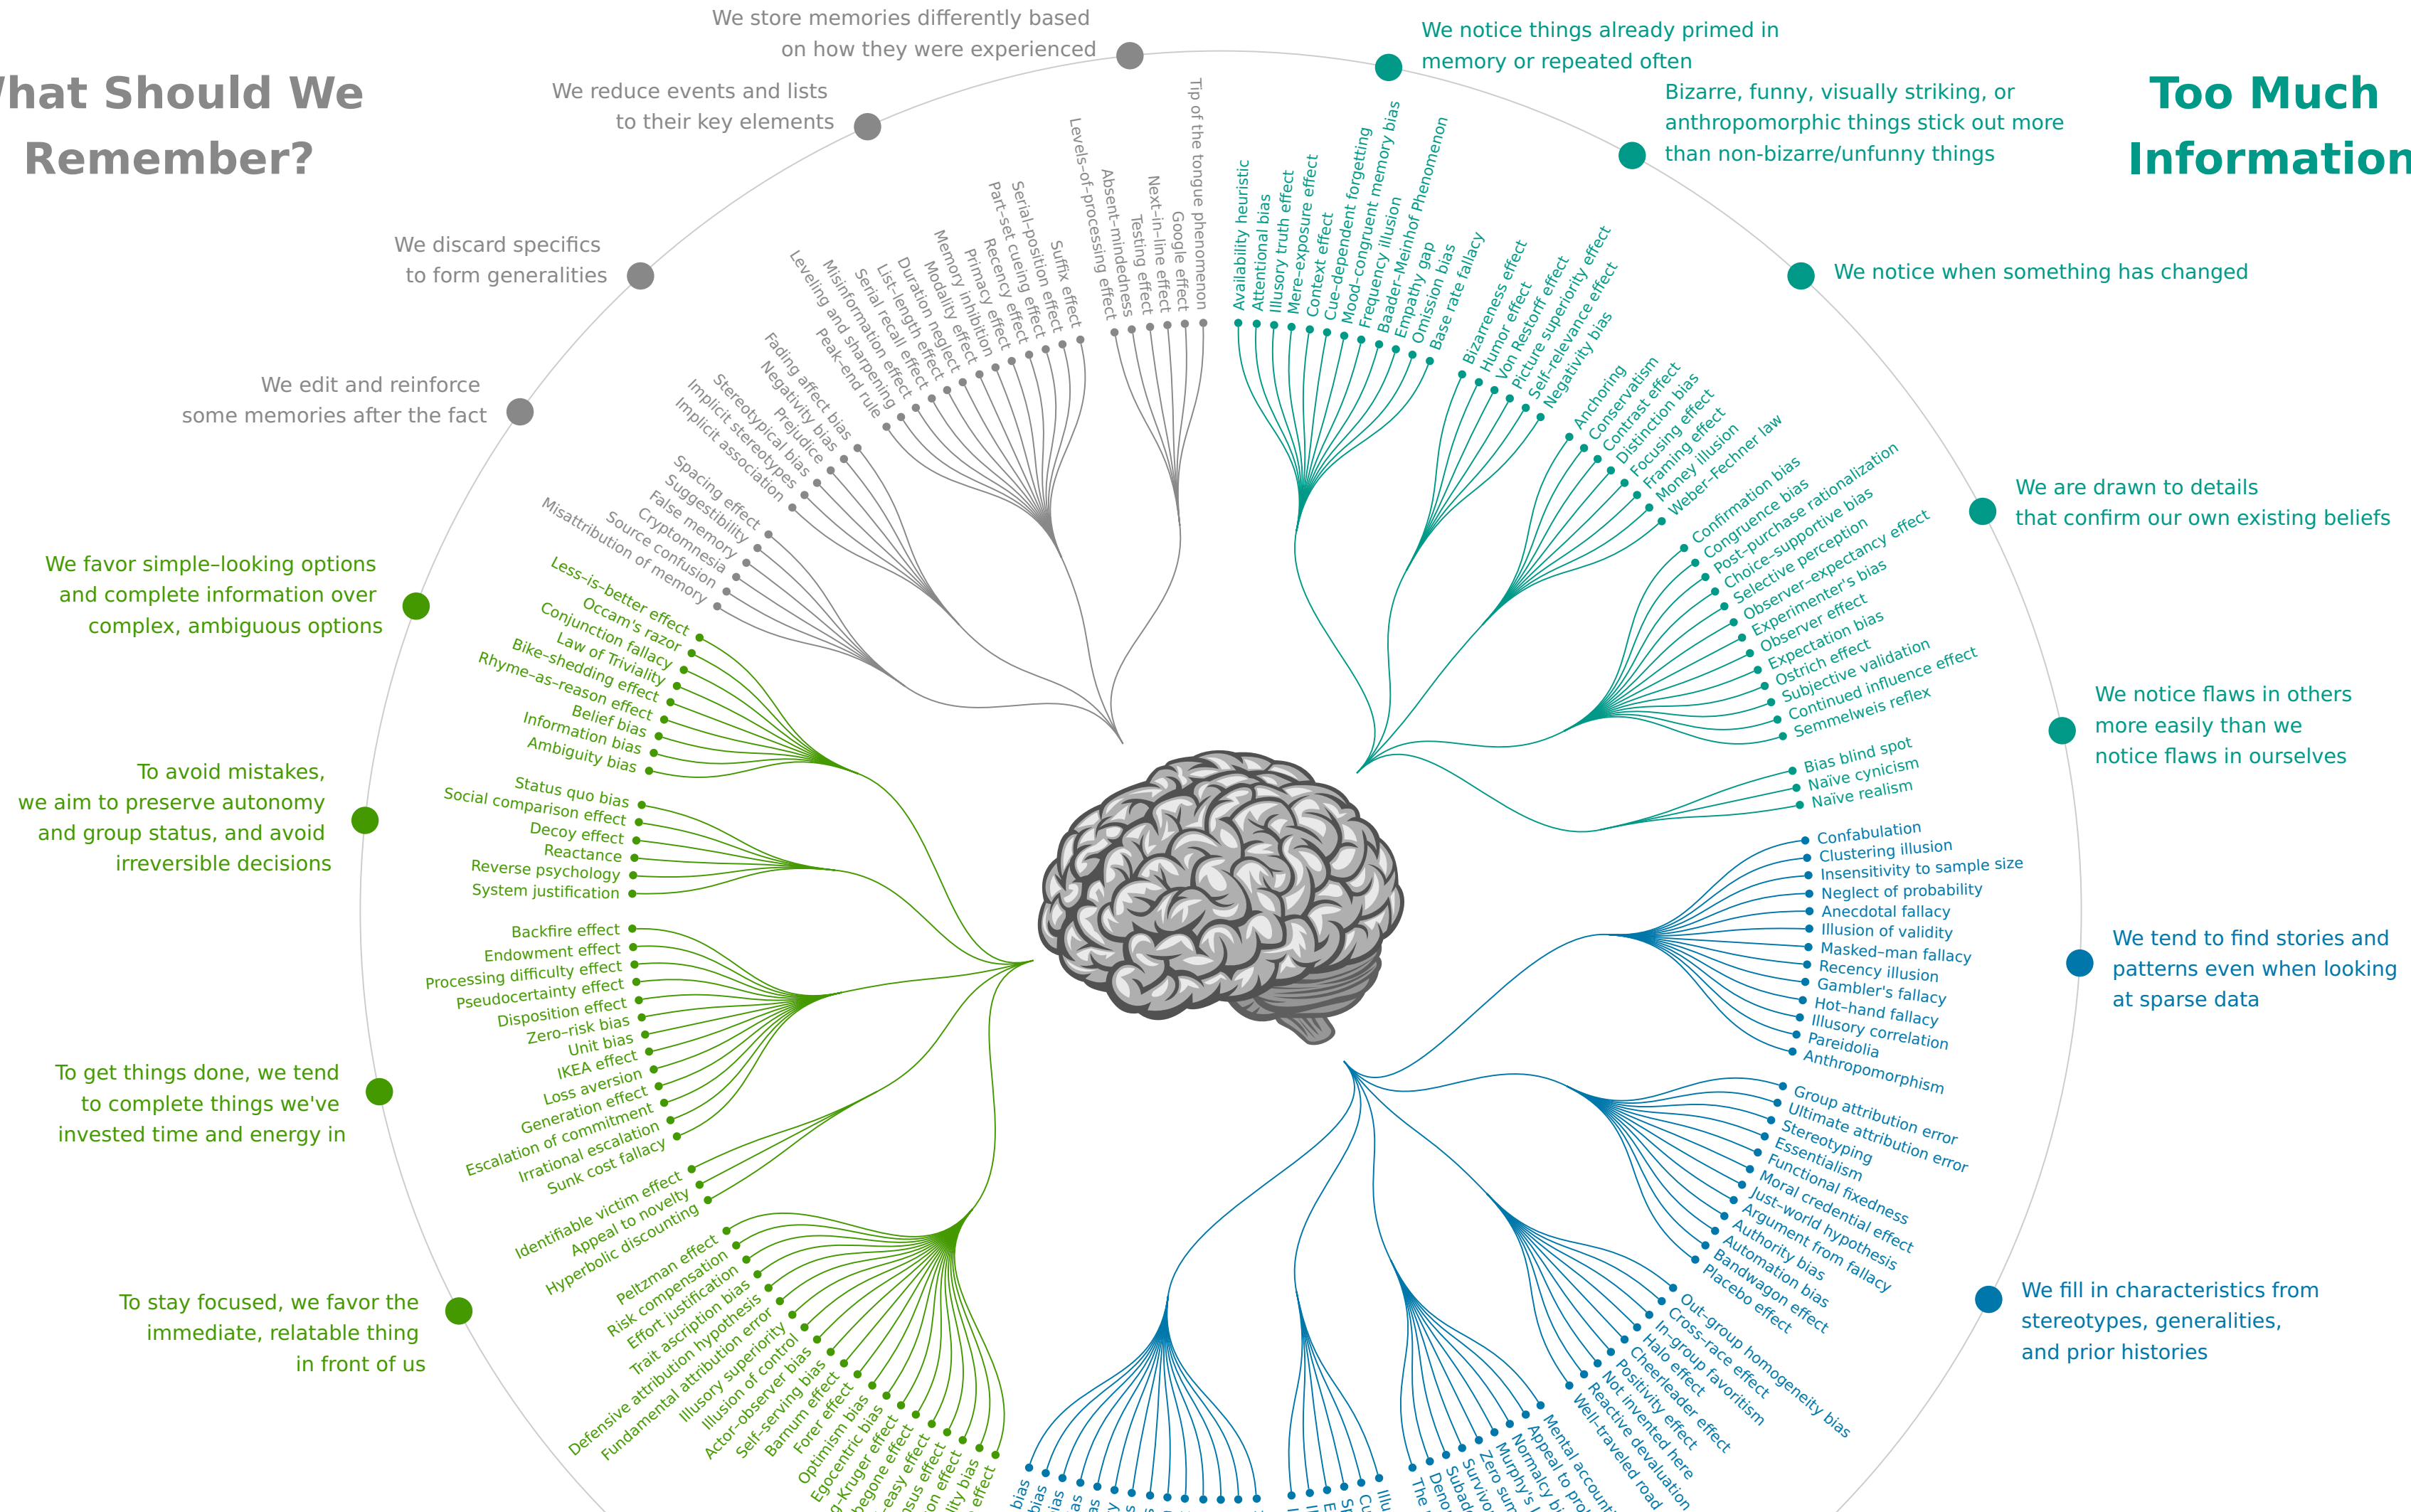
- Sesgo de **confirmación**: Tendencia a buscar, interpretar y recordar información que confirma nuestras creencias preexistentes.
- Sesgo de **anclaje**: Tendencia a depender demasiado de la primera información que se recibe.
- Sesgo de **disponibilidad**: Tendencia a sobreestimar la importancia de la información que se recuerda con mayor facilidad.
- Sesgo de **representatividad**: Tendencia a juzgar la probabilidad de un evento en función de lo bien que se ajusta a un prototipo.
- Sesgo de **atribución**: Tendencia a atribuir los éxitos a factores internos y los fracasos a factores externos.
- Sesgo de **sobrevivencia**: Tendencia a centrarse en los éxitos y a ignorar los fracasos.



# THE COGNITIVE BIAS CODEX

## What Should We Remember?

## Too Much Information







# Técnica de Lectura de Artículos Científicos

- Proposito: ¿Para qué estoy leyendo este artículo? ¿Qué información necesito obtener de él?
- Busqueda: ¿Cómo puedo evitar el sesgo de confirmación?
- Título: ¿Existe una relación con lo que busco? ¿Es relevante?
- Autores: ¿Quiénes son los autores? ¿Son expertos en el tema?
- Resumen: ¿Qué se investigó? ¿Cuál es el objetivo del estudio? ¿Cuál es el resultado que presumen?
- Resultados: ¿El resultado del resumen está respaldado por los datos presentados?
- Si los resultados parecen congruentes con el objetivo, entonces pasamos a:
- Métodos: ¿Cómo se realizó el estudio? ¿Qué técnicas se utilizaron? ¿Qué datos se recopilaron?
- Discusión: ¿Los resultados son consistentes con la literatura previa? ¿Tiene sentido el estudio? ¿Qué implicaciones tiene el estudio?
- Mis conclusiones: ¿Qué aprendí de este artículo? ¿Respaldó mi hipótesis? ¿Qué preguntas me quedan?

# Bibliometría

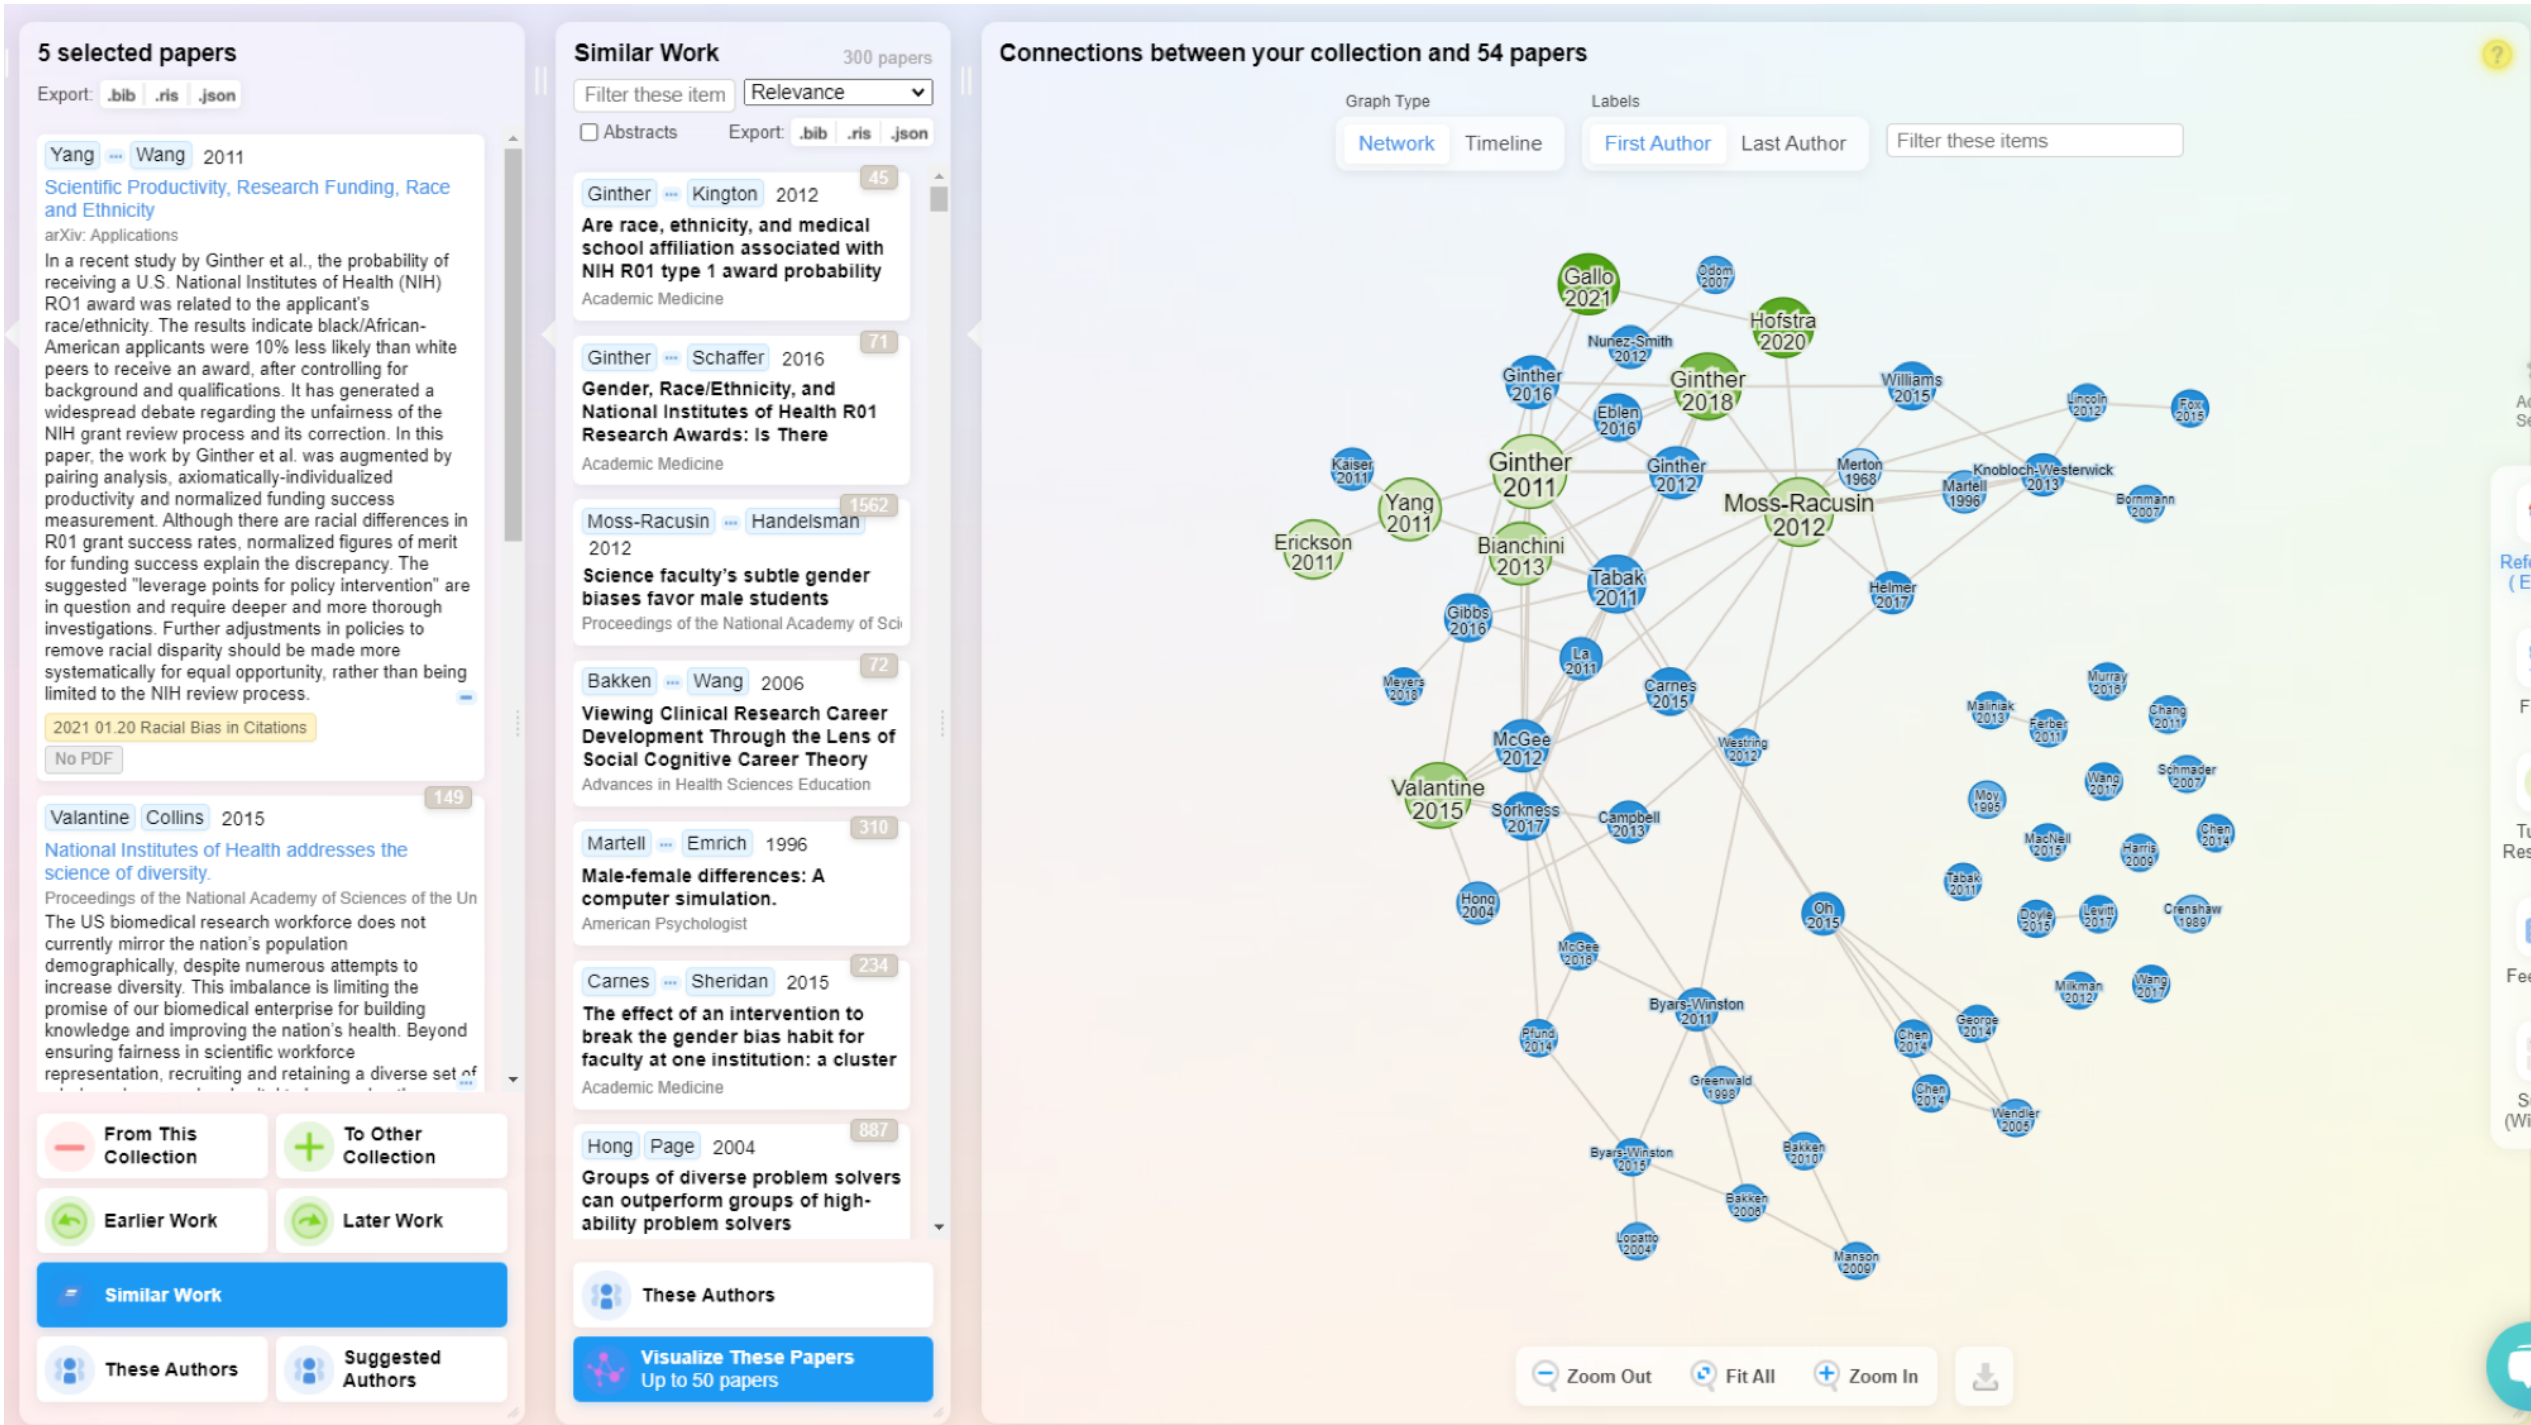
La bibliometría es el estudio **cuantitativo** de la producción, difusión, interconectividad, y uso de la información científica. La bibliometría se puede utilizar para evaluar la calidad de la investigación, identificar tendencias en la investigación y evaluar la eficacia de las políticas de investigación. Generalmente depende de las publicaciones en revistas científicas.

## Definiciones:

- **Factor de Impacto**: Medida de la frecuencia con la que los artículos de una revista científica son citados en un año determinado. 
$$IF = \frac{\text{Citas}}{\text{Publicaciones}_{2 \text{ años}}}$$
- **Índice H**: Medida de la productividad y el impacto de un científico basada en el número de citas que recibe un científico. Un autor con un dado índice H ha publicado H artículos que han sido citados al menos H veces.

# Redes Sociales

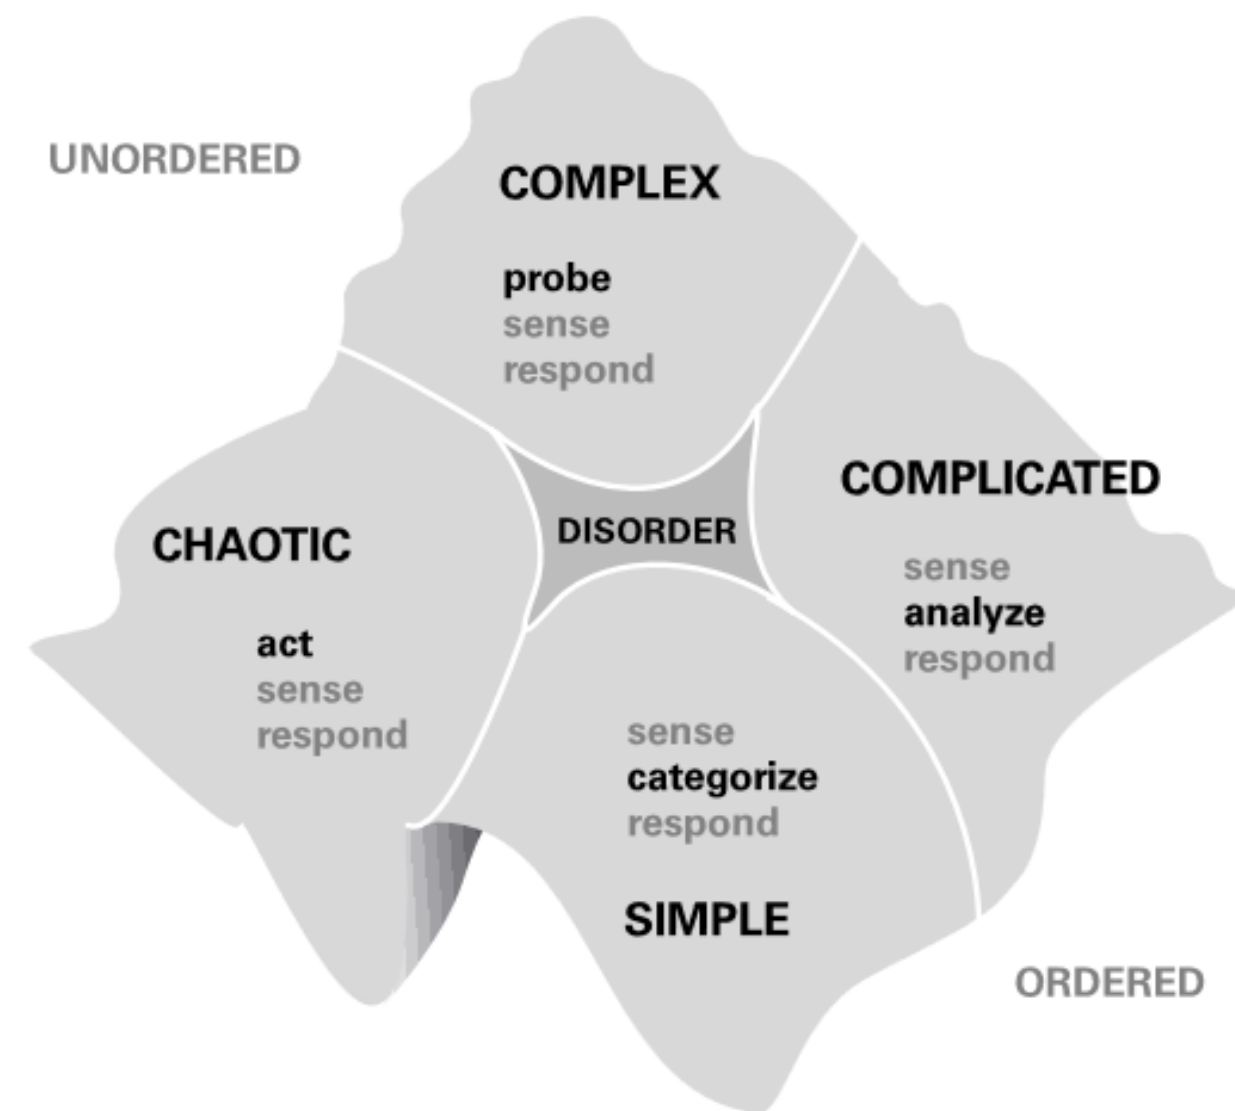
Una de las formas de medir la interconectividad de la información científica es a través de las estructuras sociales e individuos que la producen. El análisis de redes sociales es una técnica que se utiliza para analizar la estructura de las relaciones entre individuos y organizaciones. Se puede utilizar para identificar patrones de colaboración, identificar líderes de opinión y evaluar la eficacia de las políticas de investigación.



# Manejo de Proyectos

El manejo de proyectos es el proceso de planificar, organizar, dirigir y controlar los recursos para lograr un objetivo específico. El manejo de proyectos es esencial para la investigación científica, ya que permite a los investigadores planificar y ejecutar sus proyectos de manera eficiente.

En la ciencia, comunmente debemos identificar el entorno y los recursos necesarios para llevar a cabo un proyecto. Para esto les presentamos una herramienta conceptual que servir como referencia:



cynefin

img: Snowden and Boone (2007)

# Herramientas

## Buscadores

- [Google Scholar](#): Motor de búsqueda de literatura académica. (Google scholar button)
- [PubMed](#): Base de datos de literatura médica: National Library of Medicine USA.
- [Semantic Scholar](#): Motor de búsqueda de literatura científica y académica.
- [Web of Science](#): Base de datos de literatura científica para la que se requiere una suscripción.
- [Scopus](#): Base de datos de literatura científica de Elsevier.
- [Crossref](#): Base de datos de referencias y citas (Librería de metadatos).
- [Clarivate](#): Base de datos de literatura científica para la que se requiere una suscripción.
- [Paperpanda](#): Motor de búsqueda de literatura científica.
- [ConnectedPapers](#): Herramienta de visualización de referencias y citas.
- [IOP Publishing](#): Base de datos de literatura científica.
- Otros: Tenemos acceso a algunos otros buscadores científicos.



## Datos y pre-processamiento

- [OpenNeuro](#): Base de datos de datos de neuroimagen.
  - [Wikidata](#): Base de datos de conocimiento libre y abierta.
  - [Academic Torrents](#): Tecnología de datos distribuidos para la comunidad científica.
  - [Kaggle](#): Base de datos de todo tipo, para competencias de ciencia de datos.
  - [Zenodo](#): Repositorio de datos y software científicos.
  - [Open Science Framework](#): Repositorio de proyectos científicos.
  - [MNE y tutoriales](#): Herramienta open source para procesamiento de señales EEG y MEG. Incluye muy completos tutoriales.
  - [LabStreamingLayer \(LSL\)](#): Herramienta para conectividad de dispositivos usando TCP/IP.
- Toolboxes de Matlab:
- [Brainstorm](#): Procesamiento de señales EEG y MEG.
  - [FieldTrip](#): Procesamiento de señales EEG y MEG.
  - [EEGLAB](#): Procesamiento de señales EEG.
  - [SPM](#): Procesamiento de señales de neuroimagen.

# Manejo de citas

- [Zotero](#): La herramienta que yo uso.
- [Mendeley](#): La herramienta que la Dra. Sanchez Gamma usa.
- [EndNote](#): La herramienta de microsoft: tal vez ustedes tengan acceso o experiencia con ella.
- [Paperpile](#): Herramienta alternativa de gestión de referencias y citas.
- [LaTeX](#): Herramienta de escritura de documentos científicos.
- [Overleaf](#): Herramienta de escritura colaborativa de documentos científicos.
- [GoogleScholarButton](#): Complemento de exploradores para buscar literatura científica.
- [ScienceResearchAssistant](#): Complemento de Chrome para buscar literatura científica.
- [OpenAccessButton](#): Herramienta para encontrar artículos de acceso abierto.



# Análisis

- [JASP](#): Herramienta de análisis estadístico frequentista y bayesiano.
- [JAMOV](#): Herramienta de análisis estadístico basada en R.
- [R](#): Lenguaje de programación estadística.
- [R Studio](#): Entorno de desarrollo integrado para R.
- [Julia](#): Lenguaje de programación de alto rendimiento para la ciencia.
- [Python](#): Lenguaje de programación de propósito general.
- [SPSS](#): Herramienta de análisis estadístico: Aquí no promovemos la pratería, así que no la usaremos con ustedes. Existen suficientes herramientas adecuadas como para obligarlos a usar esta.
- [ResearchRabbit](#): Herramienta de exploración de redes de referencias.
- [Elicit](#): Herramienta AI de análisis de literatura científica.
- [Consensus](#): Herramienta AI útil para preguntas “Si o no”.
- [Python Scholarly](#): Herramienta de búsqueda de literatura científica en Python, usando google scholar.
- [PyBibliometrics](#): Herramienta de análisis de literatura científica en Python, principalmente scopus.
- [Python SemanticScholar](#): Herramienta de búsqueda de literatura científica y autores en Python.
- [Padron del SNII](#): Lista de investigadoras/es en México.

# Gestión de Proyectos

- [ClickUp](#): Herramienta de gestión de proyectos. Mi única herramienta que aún no es abierta. Estamos buscando alternativas.
- [Asana](#): TODO list con colaboración.
- [Trello](#): Común entre desarrolladores de software, diseñadores y equipos de marketing, usa metodo Kanban (Basado en pizarroncitos).
- [Notion](#): Herramienta de gestión de proyectos muy poderosa, para quien no sabe programar.
- [Obsidian](#): Originalmente para tomar notas, pero programada en javascript, así que tiene extensiones para todo.
- [Logseq](#): Llegó despues de Obsidian, pero es gratis y open source.
- [Vikunja](#): Herramienta de colaboración sencilla que se puede mantener en tu propio servidor.

## Comunicación

La universidad de LaSalle tiene una licencia de Microsoft Teams. Hemos estado usando WhatsApp. Teams está hecho para solucionar nuestro tipo de problemas.

# Habilidades Cognitivas

La **flexibilidad cognitiva** es la capacidad de cambiar de pensamiento o de acción en respuesta a un cambio en el entorno. Es esencial para la resolución de problemas, la toma de decisiones y la adaptación al cambio. Se puede entrenar a través de la práctica y la exposición a nuevas ideas y experiencias.

La atención plena, o **mindfulness**, es la capacidad de prestar atención propositivamente a las experiencias del momento presente sin asignar juicios de valor. Es una herramienta de meta-cognición que procuramos desarrollar en nuestro laboratorio.

Si les interesa este tema, con gusto podemos discutir sobre las habilidades cognitivas (o **herramientas de pensar**) que utilizamos en el laboratorio, pero consideramos estas dos ser las más generales y relevantes. Lectura sugerida: Dennett ([2014](#)).

# Ejercicio Ético

El ejercicio ético de la ciencia requiere de análisis crítico y reflexión sobre las implicaciones de nuestras acciones. Es un **proceso continuo y activo** de **auto-evaluación** como **individuos** y como **institución**, aunado al **dialogo** y la ejecución de acciones que promuevan los valores éticos en la ciencia.

Con esta slide buscamos establecer el continuo dialogo sobre la ética en la ciencia en un ambiente de **confianza y respeto**.

# Referencias

- Collaboration, Open Science. 2015. “Estimating the Reproducibility of Psychological Science.” *Science* 349 (6251): aac4716.
- Dennett, Daniel C. 2014. *Intuition Pumps and Other Tools for Thinking*. WW Norton & Company.
- Flood, Mark D, Victoria L Lemieux, Margaret Varga, and BL William Wong. 2016. “The Application of Visual Analytics to Financial Stability Monitoring.” *Journal of Financial Stability* 27: 180–97.
- Hofstadter, Douglas R. 1999. *Gödel, Escher, Bach: An Eternal Golden Braid*. Basic books.
- John, Leslie K, George Loewenstein, and Drazen Prelec. 2012. “Measuring the Prevalence of Questionable Research Practices with Incentives for Truth Telling.” *Psychological Science* 23 (5): 524–32.
- Klein, RA et al. 2013. “Investigating Variation in Replicability: The ‘Many Labs’ Replication Project, 14 Jun.”
- Laird, Nan. 2004. “Random Effects and the Linear Mixed Model.” In *Analysis of Longitudinal and Cluster-Correlated Data*, 8:79–96. Institute of Mathematical Statistics.
- Snowden, David J, and Mary E Boone. 2007. “A Leader’s Framework for Decision Making.” *Harvard Business Review* 85 (11): 68.
- Van Doorn, Johnny, Don Van Den Bergh, Udo Böhm, Fabian Dablander, Koen Derks, Tim Draws, Alexander Etz, et al. 2021. “The JASP Guidelines for Conducting and Reporting a Bayesian Analysis.” *Psychonomic Bulletin & Review* 28: 813–26.